Proposta de Projeto de Aplicação
Predição de mortalidade neonatal no estado do Rio de Janeiro com dados abertos do SINASC e do SIM

Cledson da Silva Araújo[1]

[1]Instituto de Computação – Universidade Federal Fluminense (UFF)
Niterói – RJ – Brasil

Disciplina: Introdução ao Aprendizado de Máquina para a Saúde (2026.2)
Prof. Flávio Luiz Seixas

1. Tema e motivação

A mortalidade neonatal (óbito de 0 a 27 dias de vida) responde pela maior parte da mortalidade infantil no Brasil e concentra-se em causas evitáveis ligadas à assistência na gestação e no parto. Um escore de risco calculado automaticamente a partir da Declaração de Nascido Vivo (DN) pode priorizar leitos de UTI neonatal, visitas domiciliares na primeira semana e a regulação de gestantes de alto risco.

2. Artigo de referência

Batista et al. (2021) [Batista et al. 2021], *Neonatal mortality prediction with routinely collected data: a machine learning approach*, BMC Pediatrics 21:322.

Os autores fizeram o linkage probabilístico entre o SINASC e o SIM do município de São Paulo, com dados identificados cedidos pela prefeitura. A coorte tinha 1.128.162 nascidos vivos em 2012–2017 e 7.282 óbitos neonatais. As 23 variáveis da DN foram usadas para treinar cinco algoritmos, com treino em 2012–2016 e teste em 2017. O melhor foi o XGBoost, com AUROC 0,971, AUPRC 0,586 e F1 0,548. Os 5% de maior risco concentraram mais de 90% dos óbitos, e as variáveis mais importantes foram Apgar, peso, anomalia congênita e idade gestacional.

Lacunas.

- O estudo usa uma única cidade e dados identificados, o que impede a reprodução por terceiros.
- O modelo depende de variáveis que só existem depois do parto (Apgar, peso).
- Não avalia calibração nem desempenho por subgrupo. Essas duas lacunas também são apontadas pela revisão sistemática de [Mangold et al. 2021]: só 45% dos estudos reportam calibração e 18% fazem validação externa.

3. Perguntas de pesquisa e hipóteses

1. **Reprodução com dados abertos.** O desempenho do artigo se mantém no estado do RJ usando apenas microdados públicos, sem nenhum identificador? *H1: AUROC $\geq$ 0,95 no modelo completo.*
2. **Risco antes do parto.** Quanto se perde com um modelo que usa só o que se sabe na admissão para o parto (mãe, gestação e pré-natal, sem Apgar, peso nem anomalia)? *H2: queda substancial de AUROC, com o modelo ainda útil para triagem.*

3. **Calibração e equidade.** O desempenho e a calibração variam por raça/cor e escolaridade da mãe e entre capital e interior? *H3: a calibração piora nos subgrupos de menor escolaridade.*

4. Dados

- **Fontes:** microdados públicos do SINASC (nascidos vivos) e do SIM (óbitos), por residência no RJ, obtidos no FTP do DATASUS sem cadastro [Ministério da Saúde – DATASUS 2026]. O download é automatizado.
- **Período:** 1.397.216 nascidos vivos em 2017–2023 e óbitos de 2017–2024. O ano de 2024 entra para captar óbitos de nascidos em dezembro de 2023.
- **Desfecho:** óbito não fetal com 0–27 dias de vida.

Linkage sem identificadores. Os arquivos públicos não trazem o número da DN. Porém, a Declaração de Óbito de menores de 1 ano repete dados do nascimento. Cada óbito é pareado a um nascido vivo por concordância exata em seis chaves compostas em cascata:

- a mais restritiva é data de nascimento + sexo + município + peso + idade da mãe + semanas de gestação + tipo de gravidez + tipo de parto;
- as seguintes toleram campos ausentes;
- em todas, só se aceitam pares 1:1.

Os resultados do linkage já foram verificados:

- 10.849 dos 12.039 óbitos neonatais do período foram pareados (**90,1%**, entre 88,5% e 91,6% conforme o ano).
- Esse percentual é comparável aos 90,8% obtidos com dados identificados nas capitais brasileiras [Maia et al. 2017].
- A fração de falsos pares, estimada por um modelo de mistura sobre campos fora das chaves, é de 6–8% nas duas chaves principais.

Essa estimativa usa a escolaridade da mãe e as perdas fetais anteriores, tomando como referência a passada completa e pares aleatórios.

5. Método

- **Conjuntos de variáveis:**
  - (A) *completo*: as 28 variáveis da DN, como no artigo;
  - (B) *pré-parto*: 17 variáveis da mãe, da gestação e do pré-natal (idade gestacional, consultas, índice de Kotelchuck, histórico obstétrico).
- **Modelos:** regressão logística (linha de base interpretável), XGBoost (modelo do artigo) [Chen and Guestrin 2016] e LightGBM [Ke et al. 2017].
- **Validação temporal**, como no artigo:
  - ajuste em 2017–2021;
  - escolha de hiperparâmetros por otimização bayesiana (Optuna/TPE) [Akiba et al. 2019], com *early stopping* e recalibração isotônica em 2022;
  - teste único, intocado, em 2023.
- **Desbalanceamento** (prevalência de $\approx$0,8%): o peso de classe é tratado como hiperparâmetro. Não se usa sobreamostragem, para preservar a calibração.

6. Avaliação

- **Métricas**, com IC 95% por bootstrap estratificado:
  - AUROC e AUPRC;
  - F1, precisão, sensibilidade e especificidade no limiar escolhido na validação;
  - escore de Brier e razão observado/esperado;
  - fração dos óbitos entre os 5% de maior risco, métrica comparável ao artigo.
- **Comparações:** ΔAUROC e ΔAUPRC entre (A) e (B) e entre XGBoost e regressão logística, por bootstrap pareado.
- **Interpretação e subgrupos:** valores SHAP [Lundberg and Lee 2017], comparados ao ranking do artigo, e curvas de calibração por subgrupo.
- **Sensibilidade ao linkage:** repetição do modelo usando só as duas chaves mais restritivas.

7. Entregas e cronograma

Etapa	Situação
Download, linkage e base analítica	concluído
Modelos, ajuste de hiperparâmetros e avaliação	concluído
README (Parte 1) e notebook comentado (Parte 2)	concluído
Relatório no formato SBC ($\leq$ 12 páginas)	concluído
Apresentação (15 min + 5 de perguntas)	slides prontos

Limitações previstas.

- Cerca de 10% dos óbitos não são pareados. Eles ficam rotulados como sobreviventes, o que tende a subestimar o desempenho.
- Os falsos pares introduzem ruído no rótulo.
- O modelo pré-parto usa a idade gestacional do parto, que é uma aproximação da estimativa disponível na admissão.

Referências

[Akiba et al. 2019] Akiba, T., Sano, S., Yanase, T., Ohta, T., and Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631.

[Batista et al. 2021] Batista, A. F. M., Diniz, C. S. G., Bonilha, E. A., Kawachi, I., and Chiavegatto Filho, A. D. P. (2021). Neonatal mortality prediction with routinely collected data: a machine learning approach. *BMC Pediatrics*, 21:322.

[Chen and Guestrin 2016] Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

[Ke et al. 2017] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, pages 3146–3154.

[Lundberg and Lee 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774.

[Maia et al. 2017] Maia, L. T. S., Souza, W. V., Mendes, A. C. G., and Silva, A. G. S. (2017). Use of linkage to improve the completeness of the SIM and SINASC in the Brazilian capitals. *Revista de Saúde Pública*, 51:112.

[Mangold et al. 2021] Mangold, C., Zoretic, S., Thallapureddy, K., Moreira, A., Chorath, K., and Moreira, A. (2021). Machine learning models for predicting neonatal mortality: A systematic review. *Neonatology*, 118:394–405.

[Ministério da Saúde – DATASUS 2026] Ministério da Saúde – DATASUS (2026). Transferência de arquivos: SINASC e SIM (microdados por uf). `ftp://ftp.datasus.gov.br/dissemin/publicos/`. Acesso em 24 set. 2026.