Predição de mortalidade neonatal no Rio de Janeiro com dados abertos: linkage SINASC × SIM sem identificadores e aprendizado de máquina

Cledson da Silva Araújo[1]

[1]Instituto de Computação – Universidade Federal Fluminense (UFF)
Niterói – RJ – Brasil

Abstract. *Batista et al. (2021) predicted neonatal death in São Paulo with XGBoost (AUROC 0.971) using identified records linked by the city. We reproduce and extend their study for the state of Rio de Janeiro using only public DATASUS microdata covering 1.397.216 live births in 2017–2023. Because the public files lack identifiers, we linked births and deaths with cascaded composite keys. This matched 90,1% of the 12.039 neonatal deaths; after discounting estimated false matches, about 85% have a true match. Models were trained on 2017–2021, tuned and recalibrated on 2022, and tested once on 2023. With all birth-certificate variables, XGBoost reached an AUROC of 0,956 (0,948–0,962) and an AUPRC of 0,576; the 5% highest-risk births held 87% of deaths, with positive net benefit at every threshold from 1% to 20%. A model restricted to information available at admission for delivery reached an AUROC of 0,890. Discrimination was insensitive to linkage errors, whereas absolute calibration depended on linkage completeness and on the 2023 rise in mortality.*

Resumo. *Batista et al. (2021) previram o óbito neonatal em São Paulo com XGBoost (AUROC de 0,971) usando registros identificados, pareados pela prefeitura. Este trabalho reproduz e estende o estudo para o estado do Rio de Janeiro usando apenas microdados públicos do DATASUS, com 1.397.216 nascidos vivos entre 2017 e 2023. Como os arquivos públicos não têm identificadores, os nascimentos foram pareados aos óbitos por chaves compostas em cascata. Foram pareados 90,1% dos 12.039 óbitos neonatais; descontados os falsos pares estimados, cerca de 85% têm um par verdadeiro. Os modelos foram treinados em 2017–2021, ajustados e recalibrados em 2022 e testados uma única vez em 2023. Com todas as variáveis da Declaração de Nascido Vivo, o XGBoost atingiu AUROC de 0,956 (0,948–0,962) e AUPRC de 0,576. Os 5% de maior risco concentraram 87% dos óbitos, e o benefício líquido foi positivo em todos os limiares de 1% a 20%. Um modelo restrito ao que se sabe na admissão para o parto atingiu AUROC de 0,890. A discriminação não foi sensível aos erros do linkage; a calibração absoluta dependeu da completude do linkage e do aumento da mortalidade em 2023.*

1. Introdução

O período neonatal (0 a 27 dias de vida) concentra a maior parte dos óbitos infantis no Brasil, e boa parte deles é considerada evitável por atenção adequada à gestação, ao parto e ao recém-nascido. No estado do Rio de Janeiro, a taxa de mortalidade neonatal (TMN) entre 2017 e 2023 foi de 8,62 óbitos por mil nascidos vivos, segundo o SIM.

A Declaração de Nascido Vivo (DN) é preenchida para todo nascimento e alimenta o SINASC. Um escore de risco calculado a partir dela pode apoiar a priorização de leitos de UTI neonatal, o transporte inter-hospitalar e a visita domiciliar na primeira semana. Batista et al. [Batista et al. 2021] mostraram que isso é viável: com as variáveis da DN do município de São Paulo, o XGBoost atingiu AUROC de 0,971.

O estudo, porém, deixa três lacunas:

- usa dados identificados, que não estão disponíveis para terceiros;
- depende de variáveis que só existem depois do parto (Apgar, peso);
- não avalia calibração nem desempenho por subgrupo, lacunas também apontadas na revisão sistemática de [Mangold et al. 2021].

As hipóteses abaixo estão como na proposta do projeto:

1. **H1 (reprodução):** com dados abertos e sem identificadores, o modelo completo atinge AUROC $\geq$ 0,95 no RJ.
2. **H2 (pré-parto):** um modelo com o que se sabe na admissão para o parto tem queda substancial de AUROC, mas continua útil para triagem.
3. **H3 (calibração e equidade):** a calibração piora nos subgrupos de menor escolaridade da mãe.

O relato segue, no que se aplica, o TRIPOD+AI [Collins et al. 2024].

2. Trabalhos relacionados

Artigo de referência. [Batista et al. 2021] fizeram o linkage probabilístico, com dados identificados, dos nascimentos do município de São Paulo em 2012–2017 (7.282 óbitos neonatais). Eles treinaram cinco algoritmos com as 23 variáveis da DN (otimização bayesiana com validação cruzada de 10 *folds*), treinaram em 2012–2016 e testaram em 2017. O XGBoost teve AUROC 0,971, AUPRC 0,586, F1 0,548, precisão 0,729 e sensibilidade 0,440, e os 5% de maior risco concentraram mais de 90% dos óbitos. As principais variáveis pelo SHAP foram o Apgar no 5º e no 1º minuto, o peso, a anomalia congênita e a idade gestacional.

Outros estudos brasileiros. [Ramos et al. 2025] usaram SINASC e SIM de todo o país (8,8 milhões de nascimentos, 2015–2017) para prever óbitos neonatais evitáveis. No XGBoost, os 5% de maior risco concentraram mais de 85% dos óbitos, sem diferença na captura entre grupos de raça/cor, escolaridade e idade materna. [Silva et al. 2025], do grupo do artigo de referência, compararam estratégias de treino com dados de oito países de baixa e média renda e obtiveram AUROC de 0,816 com indicadores recomendados pela OMS. A revisão de [Mangold et al. 2021] reuniu 11 estudos (1,26 milhão de neonatos), com AUROC entre 0,58 e 0,97; só 45% reportaram calibração e 18% fizeram validação externa.

Linkage e avaliação. [Maia et al. 2017] pareararam 90,8% dos óbitos infantis das capitais brasileiras aos nascimentos, com dados identificados e etapas determinísticas e probabilísticas; nas capitais do Sudeste, 93,1%. Para avaliar a calibração, seguimos [Van Calster et al. 2019]; para a utilidade clínica, a curva de decisão de [Vickers and Elkin 2006].

3. Dados

3.1. Fontes, versão e aspectos éticos

Foram usados os microdados do SINASC (`DNRJ2017–DNRJ2023`) e do SIM (`DORJ2017–DORJ2024`) por residência no RJ, obtidos no FTP do DATASUS sem cadastro [Ministério da Saúde – DATASUS 2026] em 24/09/2026. Todos vêm das pastas de dados definitivos; os preliminares do SIM começam em 2025. O SIM vai até 2024 para incluir os óbitos de quem nasceu no fim de 2023.

O arquivo `manifesto_dados.csv` do repositório registra, para cada arquivo, a URL, o tamanho e o hash SHA-256. Assim, uma revisão futura do DATASUS pode ser detectada.

O desfecho é o óbito não fetal com 0 a 27 dias completos de vida, calculados pela diferença entre a data do óbito e a data de nascimento.

Aspectos éticos. São dados públicos e sem identificação nominal, o que dispensa a apreciação pelo sistema CEP/Conep (Res. CNS 510/2016, art. 1º, parágrafo único [Conselho Nacional de Saúde 2016]). O próprio linkage, porém, cria um risco de reidentificação: data de nascimento, sexo, peso e município tornam o registro quase único. Por isso, o repositório publica o código, mas não a base pareada.

3.2. Linkage sem identificadores

Os arquivos públicos não trazem o número da DN, o nome da mãe nem o endereço. A Declaração de Óbito (DO) de menores de 1 ano, no entanto, repete dados do nascimento, e o estabelecimento do óbito do neonato costuma ser o hospital do parto.

Cada óbito foi pareado a um nascido vivo por concordância exata em 6 chaves compostas, aplicadas em cascata da mais restritiva à mais tolerante a campos ausentes (Tabela 1). Em cada passada, uma chave só é aceita se for única entre os nascidos e entre os óbitos ainda não pareados (pares 1:1). Duas chaves mais tolerantes foram descartadas por excesso estimado de falsos pares.

Falsos pares. Um campo que nunca entra nas chaves concorda nos pares verdadeiros com frequência c_{verd} e nos falsos com a do acaso, c_{acaso}. Assim, na passada k,

$$c_k = (1 - f_k)\, c_{\text{verd}} + f_k\, c_{\text{acaso}} \quad \Rightarrow \quad f_k = \frac{c_{\text{verd}} - c_k}{c_{\text{verd}} - c_{\text{acaso}}}. \tag{1}$$

Na estimativa:

- os campos de conferência são a escolaridade da mãe e o número de perdas fetais;
- c_{acaso} vem de pares sorteados com a mesma data e o mesmo sexo;
- **premissa:** c_{verd} é a concordância da passada 1, supondo 0% de falsos pares nela, que usa a chave completa com oito campos.

Se a passada 1 tiver falsos pares, os f_k das demais estão subestimados.

3.3. Preparação

As 28 variáveis da DN são:

Tabela 1. Chaves do linkage, pares aceitos e fração estimada de falsos pares.

	Chave	Pares	Falsos pares estimados	
			Escol. mãe	Perdas fetais
1	data + sexo + mun. + peso + id. mãe + sem. gest. + gravidez + parto	5.338	0%	0%
2	data + sexo + mun. + peso + id. mãe	3.521	6%	8%
3	data + sexo + mun. + peso + estab.	771	32%	17%
4	data + sexo + peso + id. mãe	439	11%	11%
5	data + sexo + mun. + id. mãe + sem. gest.	492	16%	13%
6	data + sexo + mun. + estab. + id. mãe	288	22%	22%

- 13 numéricas: idade da mãe e do pai, histórico obstétrico, semanas de gestação, consultas e mês de início do pré-natal, Apgar e peso;
- 14 categóricas: estado civil, escolaridade e raça/cor da mãe, gravidez, parto, sexo, anomalia, apresentação, indução, cesárea antes do trabalho de parto, quem assistiu, grupo de Robson, índice de Kotelchuck e local de nascimento;
- o indicador de residência na capital.

Nas numéricas, o código de "ignorado" (99, ou 9999 no peso) vira ausente. Nas categóricas, o "9" e o vazio viram categorias próprias. A exclusão do artigo (idade gestacional fora de 15–45 semanas) não removeu registros. A Tabela 2 mostra o gradiente da TMN; ela é 1,6 vezes maior entre filhos de mães com fundamental incompleto do que com ensino superior.

Tabela 2. Taxa de mortalidade neonatal (TMN, por mil nascidos vivos) na base pareada, 2017–2023.

Variável	Categoria	NV	Óbitos	TMN (‰)
Peso ao nascer	$<$ 1.500 g	22.725	6.468	284,6
	1.500–2.499 g	110.053	1.904	17,3
	2.500–3.999 g	1.194.900	2.336	2,0
	$\geq$ 4.000 g	69.513	141	2,0
Idade gestacional	$<$ 32 sem	23.211	6.068	261,4
	32–36 sem	133.100	2.069	15,5
	37–41 sem	1.202.793	2.449	2,0
	$\geq$ 42 sem	21.543	41	1,9
Escolaridade da mãe	Fund. incompleto ou menos	331.600	3.099	9,3
	Médio	741.665	5.810	7,8
	Superior	299.999	1.725	5,8

4. Métodos

4.1. Conjuntos de variáveis e modelos

(A) Completo: as 28 variáveis, que reproduzem o artigo.

(B) Pré-parto: as 17 variáveis conhecidas na admissão para o parto (mãe, pai, histórico obstétrico, idade gestacional, gravidez, apresentação, pré-natal, Kotelchuck e

capital). Saem as variáveis do recém-nascido e do parto. O grupo de Robson também sai, porque usa o início do trabalho de parto.

A idade gestacional é a do parto. Consultas e Kotelchuck também dependem dela, porque uma gestação mais curta tem menos consultas. Por isso, o modelo B estima o risco *dado que o parto ocorre agora, com essa idade gestacional*, e não o risco semanas antes.

Regressão logística (linha de base):

$$P(y{=}1 \mid \mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}), \qquad \sigma(z) = \frac{1}{1+e^{-z}}. \tag{2}$$

O modelo usa penalização L2 ($C \in \{0{,}01;\ 0{,}1;\ 1\}$) e pesos de classe balanceados. Imputação pela mediana com indicador de ausência, padronização e *one-hot* são ajustados só no treino.

XGBoost [Chen and Guestrin 2016] **e LightGBM** [Ke et al. 2017]: o escore é $F(\mathbf{x}) = \sum_{k=1}^{K} f_k(\mathbf{x})$ e $P(y{=}1 \mid \mathbf{x}) = \sigma(F(\mathbf{x}))$, com árvores ajustadas em sequência. Cada árvore minimiza a expansão de segunda ordem da log-loss mais $\Omega(f) = \gamma T + \frac{1}{2}\lambda\|w\|^2 + \alpha\|w\|_1$, e categorias e ausentes são tratados de forma nativa.

Complexidade. O ajuste com histogramas custa $O(Knd)$, e a predição, $O(K \cdot \text{profundidade})$ por registro. O experimento completo levou 36 minutos em 32 núcleos.

4.2. Validação e hiperparâmetros

A validação é temporal, como no artigo:

- **ajuste:** 2017–2021 (1.040.702 nascidos vivos, 8.017 óbitos);
- **validação:** 2022 (180.369, 1.388);
- **teste:** 2023 (176.145, 1.444), usado uma única vez.

Na validação foram feitos:

- a busca bayesiana (TPE, Optuna [Akiba et al. 2019]) que maximiza a AUPRC, com 15 tentativas para o XGBoost e 10 para o LightGBM e *early stopping* de 50 árvores;
- a escolha do peso da classe positiva, tratado como hiperparâmetro (nenhum, $\sqrt{n_0/n_1}$ ou n_0/n_1);
- a recalibração isotônica;
- a escolha do limiar que maximiza o F1.

Quatro escolhas precisam de justificativa. A **busca é curta** porque cada ajuste leva $\approx$20 s com 10^6 registros e a melhor AUPRC estabilizou antes da metade das tentativas (curvas no notebook). O **holdout temporal**, em vez de validação cruzada, imita o uso real: treinar no passado e aplicar no ano seguinte. Como a **mesma validação** serve para *early stopping*, busca, isotônica e limiar, as métricas de validação são otimistas, mas o teste de 2023 continua intocado. Por fim, o modelo **não foi reajustado** com 2017–2022, porque 2022 é necessário para a recalibração e o limiar.

Os hiperparâmetros finais estão no README do repositório.

4.3. Medidas de desempenho

As medidas se dividem em dois grupos:

- **Discriminação:** AUROC, AUPRC (métrica principal, com prevalência de ≈0,8%) e fração dos óbitos entre os 5% de maior risco. São calculadas pelo escore bruto do modelo, porque a isotônica é monótona mas cria empates.
- **Calibração e decisão:** Brier, razão observado/esperado (O/E), intercepto e inclinação de calibração [Van Calster et al. 2019], benefício líquido [Vickers and Elkin 2006] e métricas no limiar. São calculadas pela probabilidade recalibrada.

Os intervalos de confiança de 95% vêm de 500 reamostras bootstrap estratificadas, e os Δ entre modelos, de bootstrap pareado. A interpretação usa SHAP [Lundberg and Lee 2017] em 20.000 nascimentos de 2023.

4.4. Avaliação das premissas

Colinearidade. Na regressão logística, filhos vivos e gestações anteriores têm VIF de 18 e 17 (gestações $\approx$ partos + perdas), e partos vaginais anteriores, 6,5; as demais variáveis têm VIF $\leq$ 3,7. Isso torna instáveis os coeficientes dessas contagens, mas não a predição; a penalização L2 estabiliza o ajuste, e as árvores não dependem dessa premissa. Não interpretamos os coeficientes.

Mecanismo dos ausentes. A ausência não é aleatória, porque a TMN é maior quando o campo falta:

- consultas de pré-natal: 18,9‰ ausente contra 7,5‰ preenchido;
- Apgar 5: 27,2‰ contra 7,6‰;
- idade do pai: 8,8‰ contra 6,6‰ (ausente em 54,2%).

Isso é compatível com ausência informativa (MAR condicional à assistência ou MNAR). Por isso usamos indicadores e categorias de ausência, e não apenas imputação.

Independência. Gêmeos compartilham mãe e gestação. Eles são 2,4% dos nascimentos, mas 8,9% dos óbitos. O bootstrap trata os nascimentos como independentes, o que estreita um pouco os IC. Excluindo os múltiplos do teste, a AUROC fica em 0,954 (A) e 0,884 (B).

Linkage. As análises do viés de rótulo e de sensibilidade estão na Seção 5.1.

5. Resultados

5.1. Linkage e viés de rótulo

Foram pareados 10.849 dos 12.039 óbitos neonatais (90,1%; entre 88,5% e 91,6% por ano). As passadas 1 e 2 respondem por 82% dos pares, com até 8% de falsos pares estimados; as tolerantes chegam a 32%. A média ponderada de falsos pares é de 6%, o que deixa ≈85% dos óbitos com um par verdadeiro. A TMN da base pareada é de 7,76‰, contra 8,62‰ no SIM.

O pareamento foi de 94,3% na capital e 88,0% no interior; por raça/cor do recém-nascido (informada na DO), variou pouco, de 89,1% a 90,5%. A comparação com

[Maia et al. 2017] exige cautela: eles usaram óbitos infantis e dados identificados, e a nossa taxa inclui falsos pares.

Os 1.190 óbitos não pareados diferem dos pareados no que a própria DO informa (Tabela 3):

- faltam com muito mais frequência peso (26,7% contra 0,8%), semanas de gestação e idade da mãe, campos exigidos pelas chaves; óbitos sem peso na DO foram pareados em só 21,1% dos casos;
- moram menos na capital e morrem menos em hospital;
- têm peso mediano maior.

Logo, os óbitos que viram falsos "sobreviventes" são, em média, menos extremos, mais do interior e de registros de pior qualidade. Como a ausência de campos na DN está associada a TMN *maior* na base pareada, esse viés não tornou a ausência um sinal de sobrevivência.

Tabela 3. Óbitos neonatais pareados × não pareados, pelas informações da Declaração de Óbito.

Característica (na DO)	Pareados	Não pareados
n	10.849	1.190
Peso ausente (%)	0,8	26,7
Semanas ausentes (%)	4,9	31,6
Idade da mãe ausente (%)	2,1	32,5
Peso mediano (g)	1.100	1.408
Peso $<$ 1.500 g (%)	60,1	51,9
Óbito no 1º dia (%)	26,3	31,8
Residente na capital (%)	35,2	19,6
Óbito em hospital (%)	98,2	90,0

5.2. Desempenho

A Tabela 4 resume o teste de 2023. No conjunto A, o XGBoost teve AUROC de 0,956 (0,948–0,962) e AUPRC de 0,576 (0,553–0,605), e os 5% de maior risco concentraram 87% dos óbitos. No limiar de 2022, F1 = 0,595, precisão = 0,633 e sensibilidade = 0,562.

O ganho do XGBoost sobre a regressão logística foi pequeno: em AUROC, Δ = 0,003 (IC 0,000–0,005); em AUPRC, Δ = 0,042 (IC 0,027–0,059). O LightGBM empatou com o XGBoost.

No conjunto B, o XGBoost teve AUROC de 0,890 (0,879–0,901) e AUPRC de 0,406 (0,380–0,437). A diferença em relação a A foi ΔAUROC = 0,066 (IC 0,056–0,076) e ΔAUPRC = 0,169 (IC 0,145–0,192), e os 5% de maior risco concentraram 72% dos óbitos.

Pelo SHAP (Figura 2), as cinco principais variáveis foram:

- no modelo A: Apgar 5º min, peso ao nascer, Apgar 1º min, semanas de gestação, anomalia congênita, as mesmas do artigo;

- no modelo B: semanas de gestação, consultas de pré-natal, escolaridade da mãe, apresentação, raça/cor da mãe.

Tabela 4. Desempenho no teste de 2023 (IC 95% por bootstrap). AUROC, AUPRC e top 5% pelo escore bruto; F1, precisão e sensibilidade no limiar escolhido em 2022.

Conj.	Modelo	AUROC	AUPRC	F1	Precisão	Sensib.	Top 5%
A	LR	0,953 (0,946–0,961)	0,533 (0,509–0,563)	0,546	0,524	0,570	86%
A	XGBoost	**0,956 (0,948–0,962)**	**0,576 (0,553–0,605)**	0,595	0,633	0,562	87%
A	LightGBM	0,956 (0,949–0,963)	0,573 (0,551–0,600)	0,580	0,565	0,596	87%
B	LR	0,887 (0,875–0,898)	0,382 (0,357–0,413)	0,476	0,475	0,477	71%
B	XGBoost	**0,890 (0,879–0,901)**	**0,406 (0,380–0,437)**	0,478	0,487	0,470	72%
B	LightGBM	0,891 (0,880–0,902)	0,399 (0,372–0,429)	0,469	0,464	0,474	71%
Batista et al. (SP)		0,971	0,586	0,548	0,729	0,440	>90%

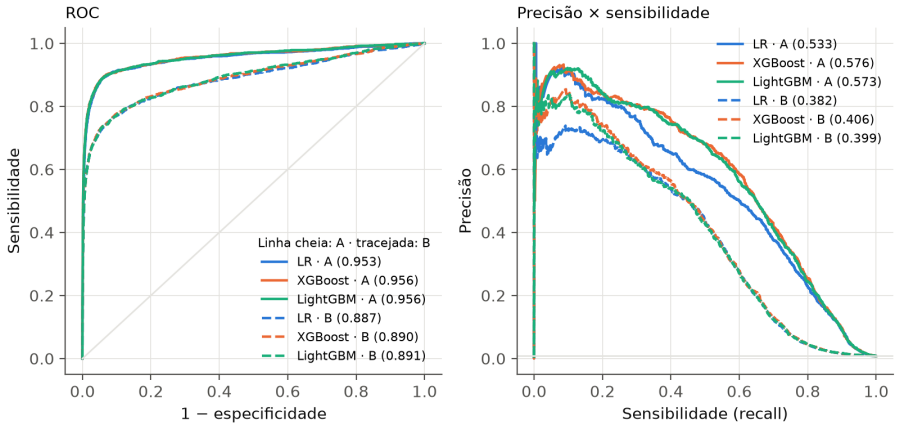


Figura 1. Curvas ROC e precisão–sensibilidade no teste de 2023. Cheia: conjunto A; tracejada: conjunto B.

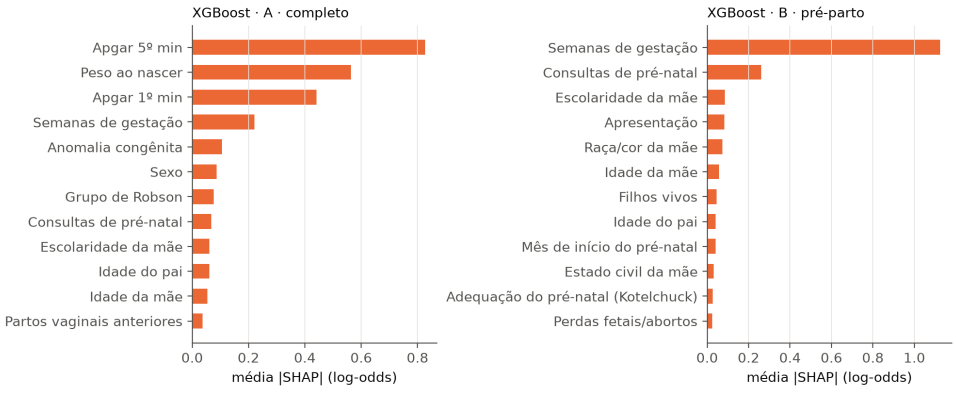


Figura 2. Importância média |SHAP| das 12 principais variáveis (XGBoost, 20.000 nascimentos de 2023).

5.3. Calibração, utilidade clínica e subgrupos

Calibração. Após a isotônica, o O/E foi de 1,02 (A) e 1,05 (B).

- No modelo A, o intercepto de calibração foi 0,026 (-0,041 a 0,094) e a inclinação 0,984 (0,958 a 1,010).
- No modelo B, o intercepto foi 0,063 (0,002 a 0,124) e a inclinação 0,993 (0,968 a 1,018).

As inclinações próximas de 1 indicam que as previsões não são extremas demais. O intercepto positivo de B coincide com o *drift* de prevalência: a TMN passou de 7,70‰ (2017–2021) para 8,20‰ em 2023, e $\ln(8{,}20/7{,}70) \approx 0{,}062$.

Utilidade clínica. Pela curva de decisão (Figura 3), o benefício líquido dos dois modelos supera o de tratar todos ou nenhum em todos os limiares de 1% a 20%. Com $p_t = 5\%$, isto é, aceitando 19 falsos alarmes por óbito identificado, o modelo A sinaliza 1,9% dos nascimentos, com benefício líquido de 5,6 por mil nascidos vivos. O modelo B tem benefício de 4,2 por mil; o máximo possível é a própria TMN, 8,20.

H3. A hipótese previa pior calibração na baixa escolaridade. Mas o O/E de mães com fundamental incompleto foi de 1,06 (0,97–1,16) no modelo B e 1,02 (0,94–1,11) no A, com IC que incluem 1 e se sobrepõem aos do ensino superior (1,03 (0,91–1,13) em B), então H3 não se confirmou. Outros dois achados (Figura 4):

- no modelo B, a AUROC foi numericamente menor na baixa escolaridade, 0,868 (0,841–0,895) contra 0,892 (0,865–0,918);
- o risco foi subestimado para filhos de mães brancas (O/E 1,15 (1,05–1,24)) e para o interior (O/E 1,08 (1,02–1,15)).

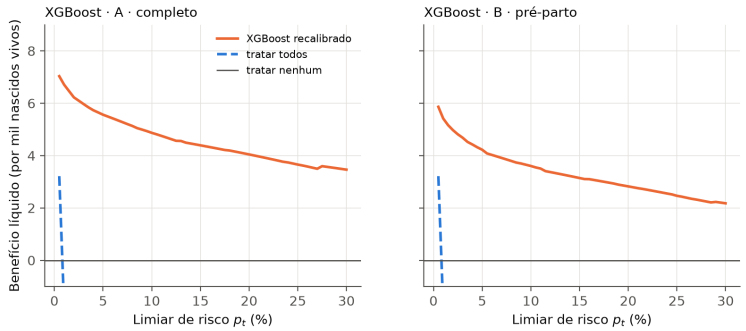


Figura 3. Curva de decisão no teste de 2023: benefício líquido por mil nascidos vivos. A calibração por decil está no notebook.

5.4. Sensibilidade ao linkage

O XGBoost foi reajustado com os mesmos hiperparâmetros e rótulos alternativos no ajuste e na validação:

- **estrito:** os nascimentos pareados nas passadas 3–6 saem;
- **pior caso:** esses nascimentos ficam, mas rotulados como sobreviventes.

Os dois cenários foram avaliados no *mesmo* teste de 2023 completo (Tabela 5).

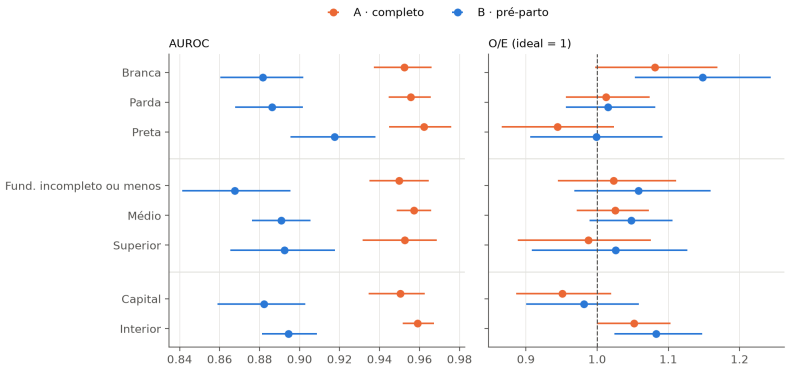


Figura 4. AUROC e O/E do XGBoost por subgrupo no teste de 2023, com IC 95% por bootstrap.

A discriminação praticamente não muda: no cenário estrito, ΔAUROC = -0,0001 (-0,0008 a 0,0006) no modelo A. Já o O/E sobe para 1,15–1,27, porque com menos positivos no treino o modelo aprende uma prevalência menor.

Tabela 5. Sensibilidade aos rótulos do linkage (XGBoost, mesmo teste de 2023; Δ por bootstrap pareado).

Conj.	Rótulos no treino	AUROC	AUPRC	O/E	ΔAUROC (IC 95%)
A	principal	0,956	0,576	1,02	–
A	estrito (sem passadas 3–6)	0,956	0,575	1,15	-0,0001 (-0,0008 a 0,0006)
A	pior caso (passadas 3–6 = 0)	0,956	0,569	1,23	-0,0005 (-0,0014 a 0,0004)
B	principal	0,890	0,406	1,05	–
B	estrito (sem passadas 3–6)	0,891	0,407	1,21	0,0011 (-0,0001 a 0,0025)
B	pior caso (passadas 3–6 = 0)	0,890	0,407	1,27	0,0002 (-0,0013 a 0,0014)

6. Discussão

H1 foi confirmada. Com dados abertos, o XGBoost teve AUROC de 0,956 e concentrou 87% dos óbitos nos 5% de maior risco, contra 0,971 e mais de 90% no artigo, com as mesmas cinco variáveis principais. Esse resultado é robusto ao linkage: nem descartar nem rotular como sobreviventes os pares duvidosos muda a AUROC.

A diferença residual para o artigo é compatível com três fatores: os ≈15% de óbitos sem par verdadeiro, que são menos extremos e, portanto, mais difíceis; a heterogeneidade do estado; e a pior qualidade da DN e da DO no interior.

H2 foi confirmada em parte. Houve queda real (ΔAUROC = 0,066, ΔAUPRC = 0,169), mas o modelo B manteve AUROC de 0,890 e benefício líquido positivo, quase tudo pela idade gestacional. O uso adequado é delimitado: estimar, na admissão para o parto, o risco dado que o nascimento ocorre agora. Isso apoia a decisão sobre transferência *in utero* para uma maternidade com UTI neonatal e o preparo da equipe. O modelo não serve para triagem precoce da gestação, porque a idade gestacional do parto e as consultas acumuladas não são conhecidas semanas antes.

H3 não foi confirmada. A subestimação no interior tem duas explicações possíveis.

- **Linkage diferencial.** O pareamento é menor no interior (88,0% contra 94,3%). Como os rótulos de treino e teste vêm do mesmo linkage, esse viés afeta sobretudo a TMN absoluta de cada região. Ele só gera O/E > 1 se a completude mudar entre os anos, o que não foi testado.
- **Fatores regionais** não capturados pela DN.

Para mães brancas, o linkage não é a explicação, porque a taxa de pareamento por raça/cor é quase uniforme. [Ramos et al. 2025] encontraram captura equivalente entre grupos, o que é coerente com a homogeneidade do nosso modelo A.

Calibração e *drift*. O modelo é bem calibrado no sentido fraco (inclinação ≈ 1). A calibração absoluta, porém, depende de dois fatores externos ao modelo: a completude do linkage, vista na sensibilidade, e o aumento da TMN em 2023. Em uso real, seria preciso recalibrar o intercepto periodicamente.

Limitações. Os rótulos são imperfeitos ($\approx$15% dos óbitos sem par verdadeiro); a validação é temporal, mas não externa; o modelo A usa variáveis posteriores ao nascimento; o bootstrap ignora a dependência entre gêmeos; e não houve óbitos suficientes para analisar mães amarelas e indígenas.

7. Conclusão

É possível reproduzir, só com dados abertos, um modelo brasileiro de predição de mortalidade neonatal com discriminação próxima à publicada, e esse resultado é robusto aos erros do linkage. A calibração absoluta, ao contrário, é sensível ao linkage e ao *drift* temporal. Um modelo na admissão para o parto mantém AUROC de 0,890 e benefício líquido positivo, para decisões de transferência *in utero*.

Como trabalhos futuros, ficam a validação externa em outras UFs, uma etapa probabilística no linkage para recuperar os óbitos com campos ausentes, a avaliação da completude do linkage por ano e região e a avaliação de impacto junto à rede de atenção materno-infantil.

Reprodutibilidade. O código, os testes, o notebook, os geradores deste relatório e dos slides e o manifesto dos dados estão em `https://github.com/CledsonSilvaAraujo/mortalidade-neonatal-rj`. O comando `python -m src.experimento` refaz todos os números a partir do FTP do DATASUS.

Referências

[Akiba et al. 2019] Akiba, T., Sano, S., Yanase, T., Ohta, T., and Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631.

[Batista et al. 2021] Batista, A. F. M., Diniz, C. S. G., Bonilha, E. A., Kawachi, I., and Chiavegatto Filho, A. D. P. (2021). Neonatal mortality prediction with routinely collected data: a machine learning approach. *BMC Pediatrics*, 21:322.

[Chen and Guestrin 2016] Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

[Collins et al. 2024] Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

[Conselho Nacional de Saúde 2016] Conselho Nacional de Saúde (2016). Resolução nº 510, de 7 de abril de 2016. Diário Oficial da União, 24 maio 2016.

[Ke et al. 2017] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, pages 3146–3154.

[Lundberg and Lee 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774.

[Maia et al. 2017] Maia, L. T. S., Souza, W. V., Mendes, A. C. G., and Silva, A. G. S. (2017). Use of linkage to improve the completeness of the SIM and SINASC in the Brazilian capitals. *Revista de Saúde Pública*, 51:112.

[Mangold et al. 2021] Mangold, C., Zoretic, S., Thallapureddy, K., Moreira, A., Chorath, K., and Moreira, A. (2021). Machine learning models for predicting neonatal mortality: A systematic review. *Neonatology*, 118:394–405.

[Ministério da Saúde – DATASUS 2026] Ministério da Saúde – DATASUS (2026). Transferência de arquivos: SINASC e SIM (microdados por uf). `ftp://ftp.datasus.gov.br/dissemin/publicos/`. Acesso em 24 set. 2026.

[Ramos et al. 2025] Ramos, A. P., Caldieraro, F., Nascimento, M. L., and Saldanha, R. (2025). Reducing inequalities using an unbiased machine learning approach to identify births with the highest risk of preventable neonatal deaths. *Population Health Metrics*, 23:59.

[Silva et al. 2025] Silva, G. F. S., Wichmann, R. M., da Silva Junior, F. C., and Chiavegatto Filho, A. D. P. (2025). Development and evaluation of machine learning training strategies for neonatal mortality prediction using multicountry data. *Scientific Reports*, 15:24278.

[Van Calster et al. 2019] Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., and Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17:230.

[Vickers and Elkin 2006] Vickers, A. J. and Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6):565–574.