Predição de mortalidade neonatal no Rio de Janeiro com dados abertos: linkage SINASC × SIM sem identificadores e aprendizado de máquina

Cledson da Silva Araújo[1]

[1]Instituto de Computação – Universidade Federal Fluminense (UFF)
Niterói – RJ – Brasil

Abstract. *Batista et al. (2021) predicted neonatal death in São Paulo with XGBoost (AUROC 0.971), but relied on identified records linked by the city. We reproduce and extend their study for the state of Rio de Janeiro using only public DATASUS microdata. The data cover 1.397.216 live births in 2017–2023. Because the public files have no identifiers, we linked births and deaths with cascaded composite keys and matched 90,1% of the 12.039 neonatal deaths, a rate comparable to what identified data achieve. Models were trained on 2017–2021, tuned and recalibrated on 2022, and tested once on 2023. With all birth-certificate variables, XGBoost reached an AUROC of 0,956 (0,948–0,962) and an AUPRC of 0,576, and the 5% highest-risk births held 87% of deaths. A model restricted to information available at admission for delivery reached an AUROC of 0,890, with good calibration. The full model performed similarly across maternal race, education and region; the pre-delivery model underestimated risk for births to white mothers and outside the capital.*

Resumo. *Batista et al. (2021) previram o óbito neonatal em São Paulo com XGBoost e obtiveram AUROC de 0,971, mas usaram registros identificados, pareados pela prefeitura. Este trabalho reproduz e estende o estudo para o estado do Rio de Janeiro usando apenas microdados públicos do DATASUS. Os dados cobrem 1.397.216 nascidos vivos entre 2017 e 2023. Como os arquivos públicos não têm identificadores, os nascimentos foram pareados aos óbitos por chaves compostas em cascata. Foram pareados 90,1% dos 12.039 óbitos neonatais, taxa comparável à obtida com dados identificados. Os modelos foram treinados em 2017–2021, ajustados e recalibrados em 2022 e testados uma única vez em 2023. Com todas as variáveis da Declaração de Nascido Vivo, o XGBoost atingiu AUROC de 0,956 (0,948–0,962) e AUPRC de 0,576; os 5% de maior risco concentraram 87% dos óbitos. Um modelo restrito ao que se sabe na admissão para o parto atingiu AUROC de 0,890, com boa calibração. O modelo completo teve desempenho semelhante entre os grupos de raça/cor e de escolaridade da mãe e entre capital e interior. O modelo pré-parto subestimou o risco para filhos de mães brancas e para residentes no interior.*

1. Introdução

O período neonatal (0 a 27 dias de vida) concentra a maior parte dos óbitos infantis no Brasil, e boa parte deles é considerada evitável por atenção adequada à gestação, ao parto e ao recém-nascido. No estado do Rio de Janeiro, a taxa de mortalidade neonatal (TMN)

entre 2017 e 2023 foi de 8,62 óbitos por mil nascidos vivos, segundo o Sistema de Informações sobre Mortalidade (SIM).

A Declaração de Nascido Vivo (DN) é preenchida para todo nascimento e alimenta o Sistema de Informações sobre Nascidos Vivos (SINASC). Um escore de risco calculado a partir dela poderia apoiar decisões como a priorização de leitos de UTI neonatal, o transporte inter-hospitalar e a visita domiciliar na primeira semana. Batista et al. [Batista et al. 2021] mostraram que isso é viável: com as variáveis da DN do município de São Paulo, o XGBoost atingiu AUROC de 0,971.

O estudo, porém, deixa três lacunas:

- usa dados identificados, que não estão disponíveis para terceiros;
- depende de variáveis que só existem depois do parto (Apgar, peso);
- não avalia calibração nem desempenho por subgrupo, lacunas também apontadas na revisão sistemática de [Mangold et al. 2021].

Este trabalho responde a três perguntas:

1. O desempenho do artigo se reproduz no estado do RJ usando apenas microdados públicos, que não têm identificadores? (H1: AUROC $\geq$ 0,95.)
2. Quanto se perde com um modelo que usa só o que se sabe na admissão para o parto? (H2: queda substancial, com o modelo ainda útil para triagem.)
3. O modelo é calibrado e funciona igualmente por raça/cor e escolaridade da mãe e entre capital e interior? (H3: pior nos subgrupos de menor escolaridade.)

2. Trabalhos relacionados

Artigo de referência. [Batista et al. 2021] fizeram o linkage probabilístico de 1.202.843 nascimentos do município de São Paulo (2012–2017) com os registros de óbito, identificando 7.282 óbitos neonatais.

- Foram usadas as 23 variáveis da DN para treinar cinco algoritmos: regressão logística, rede neural, XGBoost, LightGBM e CatBoost.
- Os hiperparâmetros foram escolhidos por otimização bayesiana com validação cruzada de 10 *folds*.
- O treino usou 2012–2016 e o teste, 2017.
- O XGBoost teve o melhor desempenho: AUROC 0,971, AUPRC 0,586, F1 0,548, precisão 0,729 e sensibilidade 0,440.
- Os 5% de maior risco concentraram mais de 90% dos óbitos.
- Pelos valores SHAP, as variáveis mais importantes foram o Apgar no 5º e no 1º minuto, o peso ao nascer, a anomalia congênita e a idade gestacional.

Modelos de mortalidade neonatal. A revisão sistemática de [Mangold et al. 2021] reuniu 11 estudos, com 1,26 milhão de neonatos, e encontrou AUROC entre 0,58 e 0,97. Peso, idade gestacional, Apgar e gemelaridade foram os preditores mais comuns. Apenas 45% dos estudos reportaram curvas de calibração, e 18% fizeram validação externa.

Linkage SIM $\times$ SINASC. [Maia et al. 2017] parearam 90,8% dos óbitos infantis das 27 capitais brasileiras aos respectivos nascimentos, combinando etapas determinísticas e probabilísticas sobre dados identificados. Nessas condições, o pareamento foi maior para óbitos neonatais do que para pós-neonatais.

3. Dados

3.1. Fontes

Foram usados os microdados públicos do SINASC (arquivos `DNRJ2017`–`DNRJ2023`) e do SIM (`DORJ2017`–`DORJ2024`) por residência no estado do RJ, obtidos no FTP do DATASUS sem cadastro [Ministério da Saúde – DATASUS 2026]. O SIM vai até 2024 para incluir os óbitos de quem nasceu no fim de 2023.

O desfecho é o óbito não fetal com 0 a 27 dias completos de vida, calculados pela diferença entre a data do óbito e a data de nascimento. Os arquivos somam 1.397.216 nascidos vivos e 12.039 óbitos neonatais.

3.2. Linkage sem identificadores

Os arquivos públicos não trazem o número da DN, o nome da mãe nem o endereço. No entanto, a Declaração de Óbito de menores de 1 ano repete dados do nascimento: data, sexo, peso, idade da mãe, semanas de gestação, tipo de gravidez e de parto. Além disso, o estabelecimento do óbito do neonato costuma ser o hospital onde ele nasceu.

Cada óbito foi pareado a um nascido vivo por concordância exata em 6 chaves compostas aplicadas em cascata (Tabela 1). As chaves vão da mais restritiva à mais tolerante a campos ausentes. Em cada passada, uma chave só é aceita se for única entre os nascidos ainda não pareados e entre os óbitos ainda não pareados (pares 1:1).

Duas chaves adicionais foram testadas e descartadas por excesso estimado de falsos pares: data + sexo + município + peso, e data + sexo + município + estabelecimento. A segunda pareia neonatos transferidos com outro recém-nascido do hospital onde morreram.

Estimativa de falsos pares. Um campo que nunca entra nas chaves concorda nos pares verdadeiros com uma frequência c_{verd} (menor que 100%, por erros de registro) e nos pares falsos com a frequência do acaso, c_{acaso}. Se a passada k tem uma fração f_k de falsos pares, a concordância observada é

$$c_k = (1 - f_k)\, c_{\text{verd}} + f_k\, c_{\text{acaso}} \quad \Rightarrow \quad f_k = \frac{c_{\text{verd}} - c_k}{c_{\text{verd}} - c_{\text{acaso}}}. \tag{1}$$

Na estimativa:

- c_{verd} vem da passada 1, a chave completa;
- c_{acaso} vem de pares sorteados com a mesma data de nascimento e o mesmo sexo;
- os campos de conferência são a escolaridade da mãe e o número de perdas fetais anteriores.

3.3. Preparação

Variáveis. São 28 variáveis da DN:

- 13 numéricas: idade da mãe e do pai, histórico obstétrico, semanas de gestação, consultas e mês de início do pré-natal, Apgar e peso;
- 14 categóricas, entre elas estado civil, escolaridade e raça/cor da mãe, tipo de gravidez e de parto, sexo, anomalia congênita, apresentação, indução, cesárea antes do trabalho de parto, grupo de Robson e índice de Kotelchuck;

Tabela 1. Chaves do linkage, número de pares e fração estimada de falsos pares.

	Chave	Pares	Falsos pares estimados	
			Escol. mãe	Perdas fetais
1	data + sexo + mun. + peso + id. mãe + sem. gest. + gravidez + parto	5.338	0%	0%
2	data + sexo + mun. + peso + id. mãe	3.521	6%	8%
3	data + sexo + mun. + peso + estab.	771	32%	17%
4	data + sexo + peso + id. mãe	439	11%	11%
5	data + sexo + mun. + id. mãe + sem. gest.	492	16%	13%
6	data + sexo + mun. + estab. + id. mãe	288	22%	22%

- um indicador de residência na capital.

Limpeza.

- Nas variáveis numéricas, os códigos de "ignorado" (99, ou 9999 no peso) viram ausentes.
- Nas categóricas, o "9" e o campo vazio viram categorias próprias, porque o não preenchimento da DN também informa sobre a assistência.
- A exclusão do artigo (idade gestacional fora de 15–45 semanas) não removeu nenhum registro, porque o SINASC já valida esse campo.

A Tabela 2 mostra a TMN pelos principais fatores. O gradiente é muito forte por peso e idade gestacional, e a TMN é 1,6 vezes maior entre filhos de mães com fundamental incompleto do que entre filhos de mães com ensino superior.

4. Métodos

4.1. Conjuntos de variáveis

(A) Completo: as 28 variáveis descritas acima, que reproduzem o artigo.

(B) Pré-parto: 17 variáveis conhecidas na admissão para o parto:

- dados da mãe e do pai;
- histórico obstétrico;
- idade gestacional;
- tipo de gravidez e apresentação;
- consultas e início do pré-natal;
- índice de Kotelchuck;
- residência na capital.

Saem do conjunto B o Apgar, o peso, a anomalia congênita, o sexo, o local e o tipo de parto, a indução, a cesárea antes do trabalho de parto, quem assistiu o parto e o grupo de Robson. O grupo de Robson sai porque usa o início do trabalho de parto.

4.2. Modelos

Regressão logística (linha de base interpretável):

$$P(y = 1 \mid \mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}. \tag{2}$$

Tabela 2. Taxa de mortalidade neonatal (TMN, por mil nascidos vivos) na base pareada, 2017–2023.

Variável	Categoria	NV	Óbitos	TMN (‰)
Peso ao nascer	$<$ 1.500 g	22.725	6.468	284,6
	1.500–2.499 g	110.053	1.904	17,3
	2.500–3.999 g	1.194.900	2.336	2,0
	$\geq$ 4.000 g	69.513	141	2,0
Idade gestacional	$<$ 32 sem	23.211	6.068	261,4
	32–36 sem	133.100	2.069	15,5
	37–41 sem	1.202.793	2.449	2,0
	$\geq$ 42 sem	21.543	41	1,9
Apgar 5º min < 7	não	1.381.935	6.233	4,5
	sim	15.281	4.616	302,1
Anomalia congênita	sim	9.614	1.294	134,6
	não	1.347.578	9.231	6,9
Raça/cor da mãe	Amarela	5.037	53	10,5
	Branca	460.545	2.928	6,4
	Indígena	1.136	9	7,9
	Parda	713.871	5.843	8,2
	Preta	191.431	1.803	9,4
Escolaridade da mãe	Fund. incompleto ou menos	331.600	3.099	9,3
	Médio	741.665	5.810	7,8
	Superior	299.999	1.725	5,8

O modelo usa penalização L2, com $C \in \{0{,}01;\ 0{,}1;\ 1\}$ escolhido na validação, e pesos de classe balanceados. Antes do ajuste há imputação pela mediana com indicador de ausência, padronização e *one-hot*, todos ajustados só no treino.

XGBoost [Chen and Guestrin 2016] **e LightGBM** [Ke et al. 2017]: o escore é uma soma de K árvores de regressão,

$$F(\mathbf{x}) = \sum_{k=1}^{K} f_k(\mathbf{x}), \qquad P(y = 1 \mid \mathbf{x}) = \sigma(F(\mathbf{x})), \tag{3}$$

ajustadas em sequência. A árvore f_k minimiza a expansão de segunda ordem da log-loss mais a regularização $\Omega(f) = \gamma T + \frac{1}{2}\lambda\|w\|^2 + \alpha\|w\|_1$, com T folhas e pesos w. As variáveis categóricas e os ausentes são tratados de forma nativa.

Complexidade.

- Com histogramas, o ajuste custa $O(K \cdot n \cdot d)$ (n registros, d variáveis), e a predição custa $O(K \cdot \text{profundidade})$ por registro.
- A regressão logística custa $O(n \cdot d')$ por iteração do L-BFGS, com d' colunas após o *one-hot*.
- O experimento completo levou 36 minutos em 32 núcleos.

4.3. Validação

A validação é temporal, como no artigo:

- **ajuste** em 2017–2021 (1.040.702 nascidos vivos, 8.017 óbitos);
- **validação** em 2022 (180.369, 1.388);
- **teste** em 2023 (176.145, 1.444), usado uma única vez.

Na validação:

- a busca bayesiana de hiperparâmetros (TPE, Optuna [Akiba et al. 2019]) maximizou a AUPRC, com 15 tentativas para o XGBoost e 10 para o LightGBM e *early stopping* de 50 árvores;
- o peso da classe positiva foi tratado como hiperparâmetro (nenhum, $\sqrt{n_0/n_1}$ ou n_0/n_1), e a busca escolheu "nenhum" nos dois conjuntos;
- uma regressão isotônica recalibrou as probabilidades;
- o limiar de classificação foi o que maximiza o F1.

A Tabela 3 lista os hiperparâmetros finais do XGBoost.

Tabela 3. Hiperparâmetros finais do XGBoost (número de árvores definido pelo *early stopping*).

Hiperparâmetro	A · completo	B · pré-parto
`learning_rate`	0,059	0,041
`max_depth`	5	4
`min_child_weight`	5,955	18,076
`subsample`	0,893	0,730
`colsample_bytree`	0,520	0,627
`reg_lambda`	0,114	0,666
`reg_alpha`	0,234	2,248
`gamma`	0,001	0,162
`scale_pos_weight`	1,000	1,000
`n_arvores`	207	409

4.4. Medidas de desempenho

As métricas se dividem em dois grupos:

- **Discriminação:** AUROC, AUPRC e fração dos óbitos entre os 5% de maior risco, a métrica que permite comparar com o artigo.
- **Calibração e decisão:** escore de Brier, razão observado/esperado (O/E) e as métricas no limiar (F1, precisão, sensibilidade, especificidade e VPN).

A AUPRC é a métrica principal porque a prevalência é de ≈0,8%. A isotônica é monótona, mas é uma função em degraus e cria empates. Por isso, a discriminação é medida pelo escore bruto do modelo, e o restante pela probabilidade recalibrada.

Os intervalos de confiança de 95% vêm de 500 reamostras bootstrap estratificadas por desfecho. As diferenças entre modelos (ΔAUROC e ΔAUPRC) usam bootstrap pareado. A interpretação usa valores SHAP [Lundberg and Lee 2017] (*TreeExplainer*) numa amostra de 20.000 nascimentos de 2023.

Como análise de sensibilidade, o XGBoost foi refeito sem os pares das passadas 3 a 6 do linkage.

5. Resultados

5.1. Linkage

Foram pareados 10.849 dos 12.039 óbitos neonatais (90,1%), com variação de 88,5% a 91,6% entre os anos (Figura 1). As passadas 1 e 2 respondem por 82% dos pares e têm até 8% de falsos pares estimados. As passadas tolerantes chegam a 32%, e a média ponderada é de 6%. A TMN da base pareada é de 7,76‰, contra 8,62‰ no SIM.

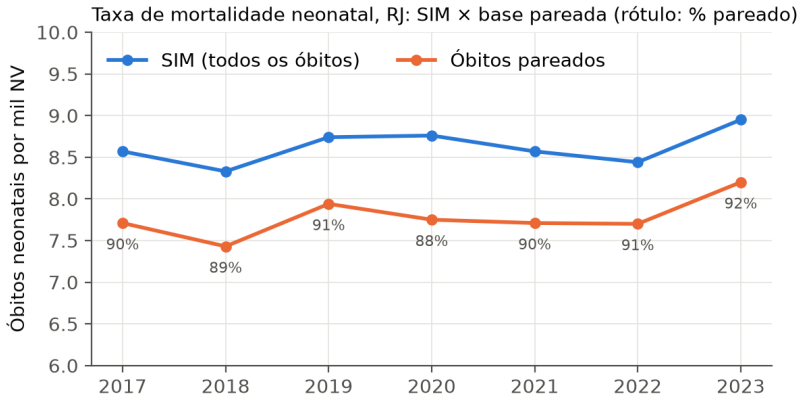


Figura 1. TMN no SIM e na base pareada por ano de nascimento; os rótulos indicam o percentual de óbitos pareados.

5.2. Desempenho

A Tabela 4 resume o teste de 2023. Com o conjunto completo (A):

- o XGBoost atingiu AUROC de 0,956 (0,948–0,962) e AUPRC de 0,576 (0,553–0,605);
- os 5% de maior risco concentraram 87% dos óbitos;
- no limiar escolhido em 2022, F1 = 0,595, precisão = 0,633, sensibilidade = 0,562 e VPN = 0,996.

O ganho do XGBoost sobre a regressão logística foi pequeno. Em AUROC, Δ = 0,003 (IC 0,000–0,005), com limite inferior praticamente nulo. Em AUPRC, o ganho foi mais claro: Δ = 0,042 (IC 0,027–0,059). O LightGBM ficou praticamente empatado com o XGBoost. A Figura 2 mostra as curvas ROC e precisão–sensibilidade.

5.3. Modelo pré-parto

Sem as variáveis do parto, o XGBoost atingiu AUROC de 0,890 (0,879–0,901) e AUPRC de 0,406 (0,380–0,437). Em relação ao modelo completo, a perda foi de ΔAUROC = 0,066 (IC 0,056–0,076) e ΔAUPRC = 0,169 (IC 0,145–0,192). Os 5% de maior risco no modelo pré-parto concentraram 72% dos óbitos, contra 87% no modelo completo (Figura 3).

As principais variáveis pelo SHAP (Figura 4) foram:

- no modelo completo: Apgar 5º min, peso ao nascer, Apgar 1º min, semanas de gestação, anomalia congênita, as mesmas cinco do artigo, com anomalia e idade gestacional em ordem trocada;
- no pré-parto: semanas de gestação, consultas de pré-natal, escolaridade da mãe, apresentação, raça/cor da mãe.

Tabela 4. Desempenho no teste de 2023 (IC 95% por bootstrap). AUROC, AUPRC e top 5% vêm do escore bruto; F1, precisão e sensibilidade, do limiar escolhido em 2022.

Conj.	Modelo	AUROC	AUPRC	F1	Precisão	Sensib.	Top 5%
A	LR	0,953 (0,946–0,961)	0,533 (0,509–0,563)	0,546	0,524	0,570	86%
A	XGBoost	**0,956 (0,948–0,962)**	**0,576 (0,553–0,605)**	0,595	0,633	0,562	87%
A	LightGBM	0,956 (0,949–0,963)	0,573 (0,551–0,600)	0,580	0,565	0,596	87%
B	LR	0,887 (0,875–0,898)	0,382 (0,357–0,413)	0,476	0,475	0,477	71%
B	XGBoost	**0,890 (0,879–0,901)**	**0,406 (0,380–0,437)**	0,478	0,487	0,470	72%
B	LightGBM	0,891 (0,880–0,902)	0,399 (0,372–0,429)	0,469	0,464	0,474	71%
Batista et al. (SP)		0,971	0,586	0,548	0,729	0,440	>90%

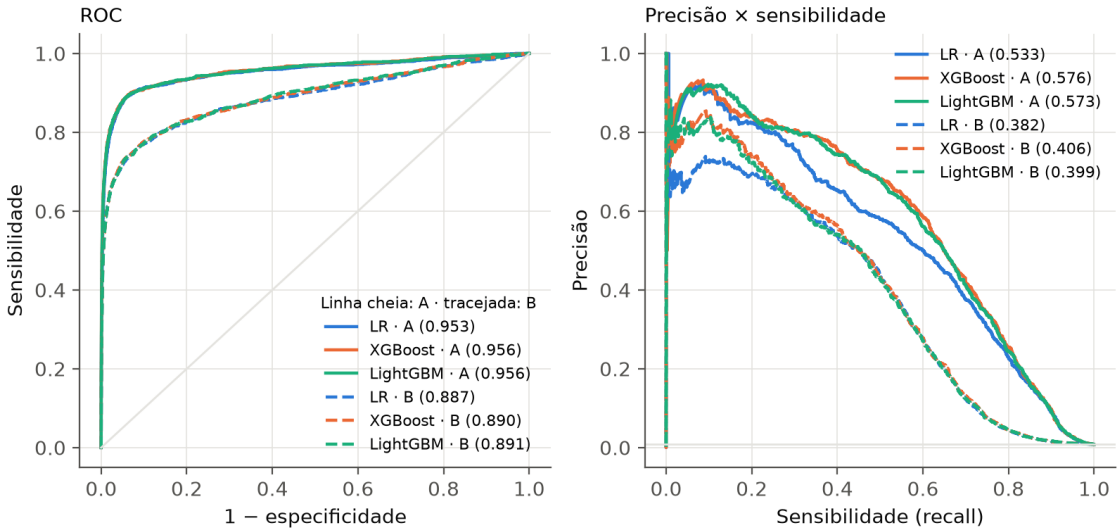


Figura 2. Curvas ROC e precisão–sensibilidade no teste de 2023. Linha cheia: conjunto completo (A); tracejada: pré-parto (B). Entre parênteses, AUROC e AUPRC.

5.4. Calibração e subgrupos

Após a recalibração, a razão O/E no teste foi de 1,02 (A) e 1,05 (B). O Brier foi de 0,0048 e 0,0059. O modelo sem recalibração já era bem calibrado (O/E 0,99 e 1,02), porque a busca escolheu não reponderar as classes (Figura 5).

Entre os subgrupos (Figura 6), a AUROC do modelo completo variou de 0,950 a 0,962, com intervalos de confiança sobrepostos. No modelo pré-parto:

- a AUROC foi menor para mães com fundamental incompleto ou menos, 0,868 (0,841–0,895), do que com superior, 0,892 (0,865–0,918), mas os intervalos se sobrepõem;
- o risco foi subestimado para filhos de mães brancas, com O/E de 1,15 (1,05–1,24);
- o risco também foi subestimado para residentes no interior, com O/E de 1,08 (1,02–1,15).

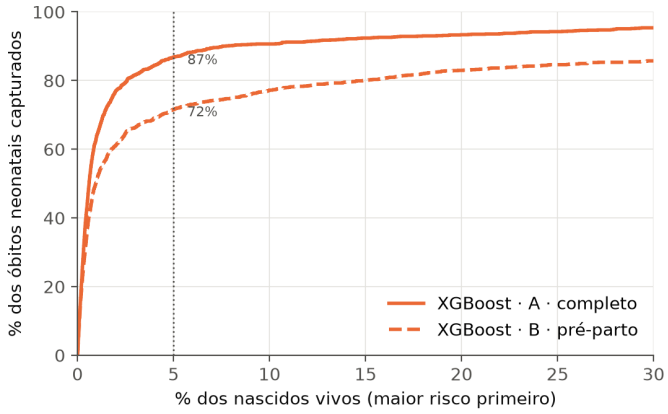


Figura 3. Fração dos óbitos capturados ao priorizar os nascimentos de maior risco (XGBoost, teste de 2023).

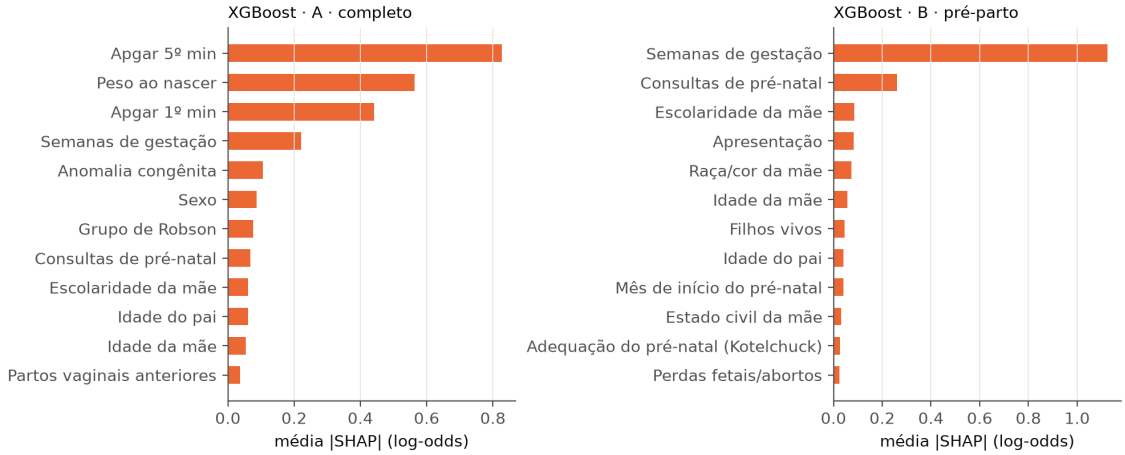


Figura 4. Importância média |SHAP| das 12 principais variáveis (XGBoost, 20.000 nascimentos de 2023).

5.5. Sensibilidade ao linkage

Sem as passadas tolerantes, a AUROC foi de 0,959 (A) e 0,891 (B), contra 0,956 e 0,890 com todos os pares. A AUPRC foi de 0,552 e 0,382.

6. Discussão

H1 (reprodução). O resultado confirma a hipótese. Com dados abertos e linkage sem identificadores, o XGBoost atingiu AUROC de 0,956 e concentrou 87% dos óbitos nos 5% de maior risco, próximo dos valores do artigo (0,971 e mais de 90%). As cinco principais variáveis também foram as mesmas.

A diferença residual tem três explicações plausíveis, que não se excluem:

- o pareamento de 90,1%: os óbitos não pareados ficam rotulados como sobreviventes;
- a população estadual é mais heterogênea do que a de um único município;
- a qualidade de preenchimento da DN varia entre os municípios do interior.

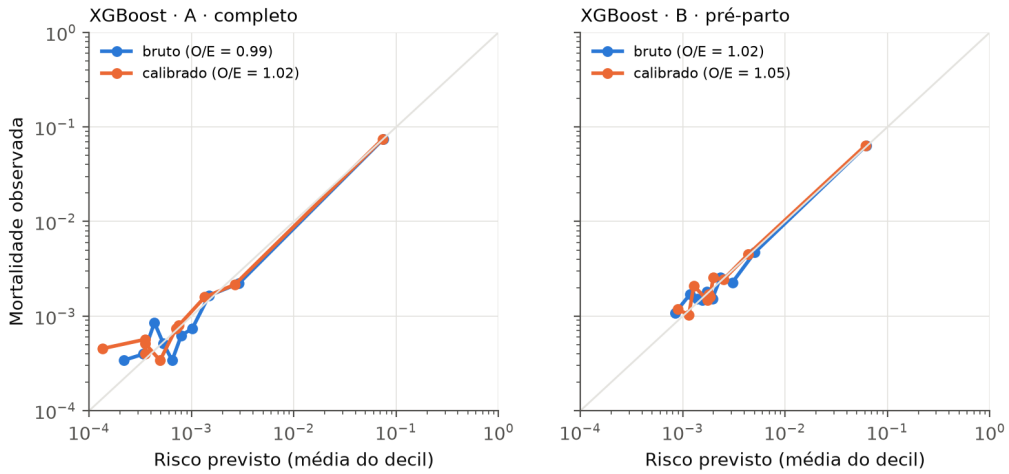


Figura 5. Mortalidade observada × risco previsto por decil de risco no teste de 2023, antes e depois da recalibração isotônica (escala logarítmica).

No limiar escolhido em 2022, a sensibilidade é maior e a precisão menor do que no artigo. Essa diferença decorre da escolha do limiar, e não do modelo.

H2 (pré-parto). A hipótese se confirma só em parte. A perda foi real (ΔAUROC = 0,066) e grande em AUPRC, mas o modelo pré-parto ficou acima do esperado, com AUROC de 0,890. Priorizando 5% das gestantes na admissão, ele captaria 72% dos óbitos neonatais, quase todo esse poder vindo da idade gestacional e do pré-natal.

Há uma ressalva: usamos a idade gestacional registrada no parto, que é uma aproximação da estimativa disponível na admissão. Na prática, esse modelo serviria à regulação de gestantes de alto risco para maternidades com UTI neonatal, e não ao cuidado depois do nascimento.

H3 (calibração e equidade). A hipótese tem apoio fraco. O modelo completo tem calibração e discriminação homogêneas entre os subgrupos. No pré-parto, a AUROC é numericamente menor na baixa escolaridade, mas os intervalos se sobrepõem. A subestimação para filhos de mães brancas e para o interior sugere que variáveis socioeconômicas e regionais carregam, nesse modelo, parte do risco que no modelo completo é explicado pelo estado do recém-nascido.

Limitações.

- Cerca de 10% dos óbitos não foram pareados, e os falsos pares introduzem ruído no rótulo. A análise de sensibilidade indica, porém, que o ruído não altera as conclusões.
- A validação é temporal, mas não externa, porque usa um único estado.
- O desempenho alto do modelo completo vem de variáveis medidas depois do nascimento, então ele identifica recém-nascidos já graves, e não uma chance de prevenção antes do parto.
- Os subgrupos amarelo e indígena não tiveram óbitos suficientes para análise.

7. Conclusão

É possível reproduzir, com dados totalmente abertos, um modelo brasileiro de predição de mortalidade neonatal com desempenho próximo ao publicado. O linkage por chaves

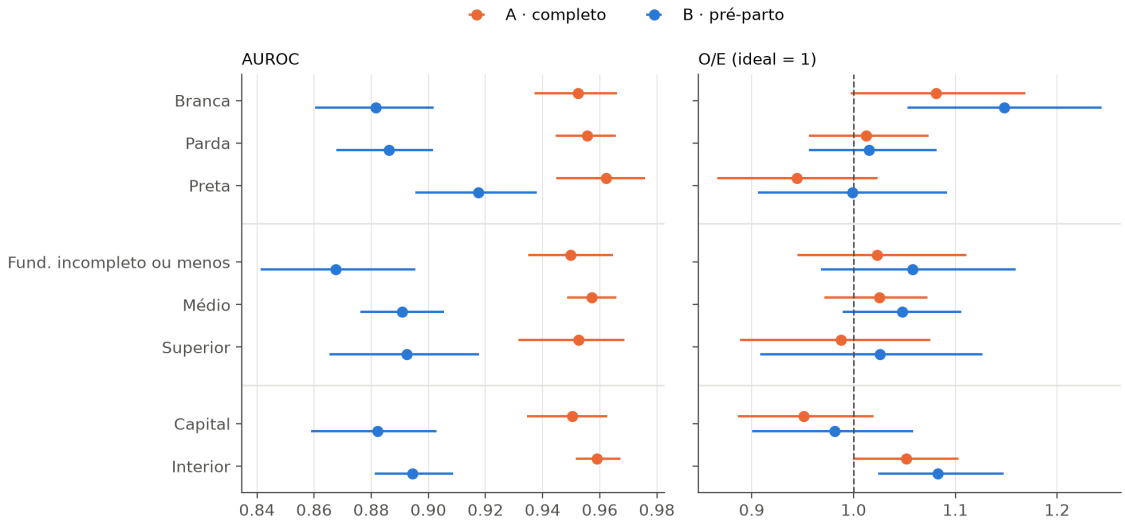


Figura 6. AUROC e razão O/E do XGBoost por subgrupo no teste de 2023, com IC 95% por bootstrap.

compostas pareou 90,1% dos óbitos, taxa comparável à de dados identificados, e pode ser reaplicado a qualquer UF. Um modelo restrito à admissão para o parto mantém AUROC de 0,890 e boa calibração.

Como trabalhos futuros:

- validação externa em outras UFs;
- etapa probabilística no linkage para recuperar os óbitos não pareados;
- extensão ao óbito pós-neonatal;
- idade gestacional estimada no pré-natal;
- avaliação do uso do escore junto a gestores da rede de atenção materno-infantil.

Reprodutibilidade. O código (download, linkage, pré-processamento, modelos, avaliação), os testes, o notebook e os geradores deste relatório e dos slides estão no repositório do projeto. O comando `python -m src.experimento` refaz todos os números a partir do FTP do DATASUS.

Referências

[Akiba et al. 2019] Akiba, T., Sano, S., Yanase, T., Ohta, T., and Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631.

[Batista et al. 2021] Batista, A. F. M., Diniz, C. S. G., Bonilha, E. A., Kawachi, I., and Chiavegatto Filho, A. D. P. (2021). Neonatal mortality prediction with routinely collected data: a machine learning approach. *BMC Pediatrics*, 21:322.

[Chen and Guestrin 2016] Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

[Ke et al. 2017] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, pages 3146–3154.

[Lundberg and Lee 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774.

[Maia et al. 2017] Maia, L. T. S., Souza, W. V., Mendes, A. C. G., and Silva, A. G. S. (2017). Use of linkage to improve the completeness of the SIM and SINASC in the Brazilian capitals. *Revista de Saúde Pública*, 51:112.

[Mangold et al. 2021] Mangold, C., Zoretic, S., Thallapureddy, K., Moreira, A., Chorath, K., and Moreira, A. (2021). Machine learning models for predicting neonatal mortality: A systematic review. *Neonatology*, 118:394–405.

[Ministério da Saúde – DATASUS 2026] Ministério da Saúde – DATASUS (2026). Transferência de arquivos: SINASC e SIM (microdados por uf). `ftp://ftp.datasus.gov.br/dissemin/publicos/`. Acesso em 24 set. 2026.