Predição de mortalidade neonatal no Rio de Janeiro com dados abertos: linkage SINASC × SIM sem identificadores e aprendizado de máquina

Versão 2: aprofundamento para publicação

Cledson da Silva Araújo[1]

[1]Instituto de Computação – Universidade Federal Fluminense (UFF)
Niterói – RJ – Brasil

Abstract. *Batista et al. (2021) predicted neonatal death in São Paulo with XGBoost (AUROC 0.971) using identified records linked by the city. We reproduce and extend their study for the state of Rio de Janeiro using only public DATASUS microdata covering 1,560,938 live births in 2017–2024. Because the public files lack identifiers, we linked births and deaths with cascaded composite keys. This matched 90.2% of the 13,471 neonatal deaths; after discounting estimated false matches, about 85% have a true match. Models were trained on 2017–2022, tuned and recalibrated on 2023, and tested once on 2024. With all birth-certificate variables, XGBoost reached an AUROC of 0.964 (95% CI 0.958–0.970) and an AUPRC of 0.603; the 5% highest-risk births held 88% of deaths, with net benefit above treating no one across clinically plausible thresholds. A model restricted to information available at admission for delivery reached an AUROC of 0.891. SHAP explanations were additive, stable across algorithms and clinically plausible. Discrimination was robust to label noise in training, whereas absolute calibration depended on linkage completeness. In this second version we probed the results as a journal reviewer would. A logistic model with birth weight, gestational age, 5-minute Apgar and congenital anomaly came within 0.005 AUROC of XGBoost, which kept a clearer advantage in AUPRC. Birth certificates completed after the death did not yield better predictions than those completed before, within the same age at death. Excluding the pandemic years did not change the results; a model never updated kept its discrimination but drifted in calibration. A gold-standard simulation showed that the deterministic keys produce few false matches when the true birth record exists, and that the pattern seen in the real data (false matches concentrated in the most tolerant key and an unrecoverable residue) is reproduced when 5–10% of deaths have no birth record in the file.*

Resumo. *Batista et al. (2021) previram o óbito neonatal em São Paulo com XGBoost (AUROC de 0,971) usando registros identificados, pareados pela prefeitura. Este trabalho reproduz e estende o estudo para o estado do Rio de Janeiro usando apenas microdados públicos do DATASUS, com 1.560.938 nascidos vivos entre 2017 e 2024. Como os arquivos públicos não têm identificadores, os nascimentos foram pareados aos óbitos por chaves compostas em cascata. Foram pareados 90,2% dos 13.471 óbitos neonatais; descontados os falsos pares estimados, cerca de 85% têm um par verdadeiro. Os modelos foram treinados*

em 2017–2022, ajustados e recalibrados em 2023 e testados uma única vez em 2024. Com todas as variáveis da Declaração de Nascido Vivo, o XGBoost atingiu AUROC de 0,964 (0,958–0,970) e AUPRC de 0,603. Os 5% de maior risco concentraram 88% dos óbitos, e o benefício líquido superou o de não intervir em toda a faixa de limiares clinicamente plausível. Um modelo restrito ao que se sabe na admissão para o parto atingiu AUROC de 0,891. As explicações SHAP foram aditivas, estáveis entre algoritmos e clinicamente plausíveis. A discriminação foi robusta a ruído de rótulo no treino; a calibração absoluta dependeu da completude do linkage. Nesta segunda versão, o trabalho foi submetido às perguntas que um revisor de revista faria. Uma regressão logística com peso, idade gestacional, Apgar 5 e anomalia congênita ficou a 0,005 (0,002 a 0,007) de AUROC do XGBoost, que manteve vantagem mais clara em AUPRC. Declarações de nascido vivo preenchidas depois do óbito não foram mais bem previstas que as preenchidas antes, na mesma faixa de idade no óbito. Excluir os anos de pandemia não mudou os resultados; um modelo nunca atualizado manteve a discriminação, mas perdeu calibração. Uma simulação com padrão-ouro mostrou que as chaves determinísticas geram poucos falsos pares quando a DN verdadeira existe, e que o padrão observado nos dados reais (falsos pares concentrados na chave mais tolerante e um resíduo irrecuperável) aparece quando 5 a 10% dos óbitos não têm DN na base.

1. Introdução

O período neonatal (0 a 27 dias de vida) concentra a maior parte dos óbitos infantis no Brasil, e boa parte deles é considerada evitável por atenção adequada à gestação, ao parto e ao recém-nascido. No estado do Rio de Janeiro, a taxa de mortalidade neonatal (TMN) entre 2017 e 2024foi de 8,63 óbitos por mil nascidos vivos, segundo o SIM.

A Declaração de Nascido Vivo (DN) é preenchida para todo nascimento e alimenta o SINASC. Um escore de risco calculado a partir dela pode apoiar a priorização de leitos de UTI neonatal, o transporte inter-hospitalar e a visita domiciliar na primeira semana. Batista et al. [Batista et al. 2021] mostraram que isso é viável: com as variáveis da DN do município de São Paulo, o XGBoost atingiu AUROC de 0,971.

O estudo, porém, usa dados identificados, indisponíveis para terceiros; depende de variáveis que só existem depois do parto (Apgar, peso); e não avalia calibração nem desempenho por subgrupo, lacunas também apontadas por [Mangold et al. 2021].

As hipóteses abaixo estão como na proposta do projeto:

1. **H1 (reprodução):** com dados abertos e sem identificadores, o modelo completo atinge AUROC $\geq$ 0,95 no RJ.
2. **H2 (pré-parto):** um modelo com o que se sabe na admissão para o parto tem queda substancial de AUROC, mas continua útil para triagem.
3. **H3 (calibração e equidade):** a calibração piora nos subgrupos de menor escolaridade da mãe.

Versão 2. A primeira versão (Seções 3–5.5) é o projeto da disciplina. Esta versão acrescenta a Seção 6, que responde a sete perguntas que um revisor faria antes de aceitar o trabalho em uma revista:

Q1. Um escore simples, com três ou quatro variáveis, faz o mesmo que o XGBoost?
Q2. Há vazamento de informação na DN, ou seja, campos preenchidos depois do óbito?
Q3. Os anos de pandemia (2020–2021) distorcem o treino?
Q4. O desempenho depende das variáveis que também são chave do linkage?
Q5. A calibração se degrada ano a ano se o modelo não for atualizado?
Q6. O estimador de falsos pares acerta quando a verdade é conhecida?
Q7. Uma etapa probabilística recupera os óbitos que ficaram sem par?

O relato segue, no que se aplica, o TRIPOD+AI [Collins et al. 2024]. Tabelas e figuras adicionais (chaves do linkage, sensibilidade, subgrupos, importância SHAP) estão no notebook do repositório, citado como *material suplementar*.

2. Trabalhos relacionados

Artigo de referência. [Batista et al. 2021] fizeram o linkage probabilístico, com dados identificados, dos nascimentos do município de São Paulo em 2012–2017 (7.282 óbitos neonatais). Eles treinaram cinco algoritmos com as 23 variáveis da DN (otimização bayesiana com validação cruzada de 10 *folds*), treinaram em 2012–2016 e testaram em 2017. O XGBoost teve AUROC 0,971, AUPRC 0,586, F1 0,548, precisão 0,729 e sensibilidade 0,440, e os 5% de maior risco concentraram mais de 90% dos óbitos. As principais variáveis pelo SHAP foram o Apgar no 5º e no 1º minuto, o peso, a anomalia congênita e a idade gestacional.

Outros estudos brasileiros. [Ramos et al. 2025] usaram SINASC e SIM de todo o país (8,8 milhões de nascimentos, 2015–2017) para prever óbitos neonatais evitáveis. No XGBoost, os 5% de maior risco concentraram mais de 85% dos óbitos, sem diferença na captura entre grupos de raça/cor, escolaridade e idade materna. [Silva et al. 2025], do grupo do artigo de referência, compararam estratégias de treino com dados de oito países de baixa e média renda e obtiveram AUROC de 0,816 com indicadores recomendados pela OMS. A revisão de [Mangold et al. 2021] reuniu 11 estudos (1,26 milhão de neonatos), com AUROC entre 0,58 e 0,97; só 45% reportaram calibração e 18% fizeram validação externa.

Linkage e avaliação. [Maia et al. 2017] pareararam 90,8% dos óbitos infantis das capitais brasileiras aos nascimentos, com dados identificados e etapas determinísticas e probabilísticas; nas capitais do Sudeste, 93,1%. A etapa probabilística da Seção 6 segue o modelo de [Fellegi and Sunter 1969]. Para avaliar a calibração, seguimos [Van Calster et al. 2019]; para a utilidade clínica, a curva de decisão de [Vickers and Elkin 2006].

3. Dados

3.1. Fontes, versão e aspectos éticos

Foram usados os microdados do SINASC (`DNRJ2017`–`DNRJ2024`) e do SIM (`DORJ2017`–`DORJ2025`) por residência no RJ, obtidos no FTP do DATASUS sem cadastro [Ministério da Saúde – DATASUS 2026] em 24/09/2026. O SIM vai até 2025 para incluir os óbitos de quem nasceu no fim de 2024. Todos os arquivos são definitivos, exceto o SIM 2025, ainda preliminar, que só contribui com óbitos de nascidos em dezembro de 2024.

O arquivo `manifesto_dados.csv` do repositório registra, para cada arquivo, a URL, o tamanho e o hash SHA-256. Assim, uma revisão futura do DATASUS pode ser detectada.

O desfecho é o óbito não fetal com 0 a 27 dias completos de vida, calculados pela diferença entre a data do óbito e a data de nascimento.

Aspectos éticos. São dados públicos e sem identificação nominal, o que dispensa a apreciação pelo sistema CEP/Conep (Res. CNS 510/2016, art. 1º, parágrafo único [Conselho Nacional de Saúde 2016]). O próprio linkage, porém, cria um risco de reidentificação: data de nascimento, sexo, peso e município tornam o registro quase único. Por isso, o repositório publica o código, mas não a base pareada.

3.2. Linkage sem identificadores

Os arquivos públicos não trazem o número da DN, o nome da mãe nem o endereço. A Declaração de Óbito (DO) de menores de 1 ano, no entanto, repete dados do nascimento, e o estabelecimento do óbito do neonato costuma ser o hospital do parto.

Cada óbito foi pareado a um nascido vivo por concordância exata em 6 chaves compostas, aplicadas em cascata da mais restritiva à mais tolerante a campos ausentes (a primeira usa data de nascimento, sexo, município, peso, idade da mãe, semanas, gravidez e parto; as seguintes retiram campos ou usam o estabelecimento). Em cada passada, uma chave só é aceita se for única entre os nascidos e entre os óbitos ainda não pareados (pares 1:1). Duas chaves mais tolerantes foram descartadas por excesso estimado de falsos pares.

Falsos pares. Um campo que nunca entra nas chaves concorda nos pares verdadeiros com frequência c_{verd} e nos falsos com a do acaso, c_{acaso}. Assim, na passada k,

$$c_k = (1 - f_k)\, c_{\text{verd}} + f_k\, c_{\text{acaso}} \quad \Rightarrow \quad f_k = \frac{c_{\text{verd}} - c_k}{c_{\text{verd}} - c_{\text{acaso}}}. \tag{1}$$

Os campos de conferência são a escolaridade da mãe e o número de perdas fetais, e c_{acaso} vem de pares sorteados com a mesma data e o mesmo sexo. **Premissa:** c_{verd} é a concordância da passada 1, supondo 0% de falsos pares nela (chave completa, oito campos); se a passada 1 tiver falsos pares, os f_k das demais estão subestimados.

3.3. Preparação

As 28 variáveis da DN são 13 numéricas (idade da mãe e do pai, histórico obstétrico, semanas de gestação, consultas e mês de início do pré-natal, Apgar e peso), 14 categóricas (estado civil, escolaridade e raça/cor da mãe, gravidez, parto, sexo, anomalia, apresentação, indução, cesárea antes do trabalho de parto, quem assistiu, grupo de Robson, Kotelchuck e local de nascimento) e a residência na capital.

Nas numéricas, o código de "ignorado" (99, ou 9999 no peso) vira ausente. Nas categóricas, o "9" e o vazio viram categorias próprias. A exclusão do artigo (idade gestacional fora de 15–45 semanas) não removeu registros. O gradiente da TMN é muito forte: 285‰ abaixo de 1.500 g contra 1,9‰ entre 2.500 e 3.999 g; 262‰ abaixo de 32 semanas contra 2,0‰ a termo; 306‰ com Apgar 5 menor que 7; e 1,6 vezes maior com mãe de fundamental incompleto do que de ensino superior.

4. Métodos

4.1. Conjuntos de variáveis e modelos

(A) Completo: as 28 variáveis, que reproduzem o artigo.

(B) Pré-parto: as 17 variáveis conhecidas na admissão para o parto (mãe, pai, histórico obstétrico, idade gestacional, gravidez, apresentação, pré-natal, Kotelchuck e capital). Saem as variáveis do recém-nascido e do parto. O grupo de Robson também sai, porque usa o início do trabalho de parto.

A idade gestacional é a do parto. Consultas e Kotelchuck também dependem dela, porque uma gestação mais curta tem menos consultas. Por isso, o modelo B estima o risco *dado que o parto ocorre agora, com essa idade gestacional*, e não o risco semanas antes.

Regressão logística (linha de base):

$$P(y{=}1 \mid \mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}), \qquad \sigma(z) = \frac{1}{1+e^{-z}}. \tag{2}$$

O modelo usa penalização L2 ($C \in \{0{,}01;\ 0{,}1;\ 1\}$) e pesos de classe balanceados. Imputação pela mediana com indicador de ausência, padronização e *one-hot* são ajustados só no treino.

XGBoost [Chen and Guestrin 2016] **e LightGBM** [Ke et al. 2017]: o escore é $F(\mathbf{x}) = \sum_{k=1}^{K} f_k(\mathbf{x})$ e $P(y{=}1 \mid \mathbf{x}) = \sigma(F(\mathbf{x}))$, com árvores ajustadas em sequência. Cada árvore minimiza a expansão de segunda ordem da log-loss mais $\Omega(f) = \gamma T + \frac{1}{2}\lambda\|w\|^2 + \alpha\|w\|_1$, e categorias e ausentes são tratados de forma nativa.

Complexidade. O ajuste com histogramas custa $O(Knd)$, e a predição, $O(K \cdot \text{profundidade})$ por registro. O experimento completo levou 41 minutos em 32 núcleos.

4.2. Validação e hiperparâmetros

A validação é temporal, como no artigo: **ajuste** em 2017–2022(1.221.071 nascidos vivos, 9.405 óbitos), **validação** em 2023 (176.145, 1.444) e **teste** em 2024 (163.722, 1.306), usado uma única vez. Na validação foram feitos a busca bayesiana (TPE, Optuna [Akiba et al. 2019]) que maximiza a AUPRC, com 15 tentativas para o XGBoost e 10 para o LightGBM e *early stopping* de 50 árvores; a escolha do peso da classe positiva (nenhum, $\sqrt{n_0/n_1}$ ou n_0/n_1); a recalibração isotônica; e o limiar que maximiza o F1.

Quatro escolhas precisam de justificativa. A **busca é curta** porque cada ajuste leva $\approx$20 s com 10^6 registros e, no XGBoost, as cinco melhores tentativas ficaram a no máximo 0,005 de AUPRC da melhor (curvas no notebook), o que indica um platô. O **holdout temporal**, em vez de validação cruzada, imita o uso real: treinar no passado e aplicar no ano seguinte. Como a **mesma validação** serve para *early stopping*, busca, isotônica e limiar, as métricas de validação são otimistas, mas o teste de 2024 continua intocado. Por fim, o modelo **não foi reajustado** com 2017–2023, porque 2023 é necessário para a recalibração e o limiar.

Os hiperparâmetros finais estão no README do repositório.

4.3. Medidas de desempenho

As medidas de **discriminação** são AUROC, AUPRC (principal, com prevalência de ≈0,8%) e fração dos óbitos entre os 5% de maior risco, calculadas pelo escore bruto, porque a isotônica é monótona mas cria empates. As de **calibração e decisão** são Brier, razão observado/esperado (O/E), intercepto, inclinação e curva de calibração [Van Calster et al. 2019], benefício líquido [Vickers and Elkin 2006] e métricas no limiar, calculadas pela probabilidade recalibrada.

Os intervalos de confiança de 95% vêm de 500 reamostras bootstrap estratificadas, e os Δ entre modelos, de bootstrap pareado. A interpretação usa SHAP [Lundberg and Lee 2017] em 20.000 nascimentos de 2024.

4.4. Avaliação das premissas

Colinearidade. Na regressão logística, filhos vivos e gestações anteriores têm VIF de 20 e 22 (gestações ≈ partos + perdas); as demais variáveis têm VIF $\leq$ 4,6. Isso torna instáveis os coeficientes dessas contagens, mas não a predição; a penalização L2 estabiliza o ajuste, e as árvores não dependem dessa premissa. Não interpretamos os coeficientes.

Mecanismo dos ausentes. A ausência não é aleatória, porque a TMN é maior quando o campo falta: consultas de pré-natal, 19,7‰ contra 7,5‰; Apgar 5, 27,6‰ contra 7,6‰; idade do pai (ausente em 54,7%), 8,8‰ contra 6,6‰. Isso é compatível com ausência informativa (MAR condicional à assistência ou MNAR). Por isso usamos indicadores e categorias de ausência, e não apenas imputação.

Independência. Gêmeos compartilham mãe e gestação. Eles são 2,3% dos nascimentos, mas 10,2% dos óbitos. O bootstrap trata os nascimentos como independentes, o que estreita um pouco os IC. Excluindo os múltiplos do teste, a AUROC fica em 0,963 (A) e 0,882 (B).

Linkage. As análises do viés de rótulo e de sensibilidade estão na Seção 5.1.

5. Resultados

5.1. Linkage e viés de rótulo

Foram pareados 12.155 dos 13.471 óbitos neonatais (90,2%; entre 88,5% e 91,6% por ano). As passadas 1 e 2 respondem por 82% dos pares, com até 8% de falsos pares estimados; as tolerantes chegam a 31%. A média ponderada de falsos pares é de 6%, o que deixa ≈85% dos óbitos com um par verdadeiro. A TMN da base pareada é de 7,79‰, contra 8,63‰ no SIM.

O pareamento foi de 94,3% na capital e 88,2% no interior. Por raça/cor do *recém-nascido* (a única informada na DO), variou pouco, de 89,4% a 90,6%; a raça/cor da *mãe*, usada nos subgrupos, não está na DO. A comparação com [Maia et al. 2017] exige cautela: eles usaram óbitos infantis e dados identificados, e a nossa taxa inclui falsos pares.

Os 1.316 óbitos não pareados têm um perfil diferente no que a própria DO informa (Tabela 2): faltam com muito mais frequência peso (26,8% contra 0,8%), semanas e idade da mãe, campos exigidos pelas chaves (óbitos sem peso na DO foram pareados em só 20,7% dos casos); moram menos na capital; e morrem mais no 1º dia e menos em hospital, o que sugere óbito precoce fora do hospital ou em trânsito. O peso mediano

maior dos não pareados não indica menor gravidade, porque é calculado só entre quem tem o peso preenchido, uma comparação com seleção. Como a ausência de campos na DN está associada a TMN *maior* na base pareada, esse viés não tornou a ausência um sinal de sobrevivência.

Completude por ano e região. A completude do linkage foi estável entre os anos nas duas regiões. Em 2024, ela foi 0,3 ponto maior que no treino na capital e 1,6 pontos no interior (Tabela 1). Só pelo linkage, isso deslocaria o O/E em 1,003 e 1,018, uma diferença de $\approx$1,5% entre as regiões, bem menor que a diferença de O/E observada.

Tabela 1. Completude do linkage e O/E por região (XGBoost recalibrado, teste de 2024).

Região	Pareamento treino (2017–2023)	Pareamento 2024	O/E esperado só pelo linkage	O/E A (recalibr.)	O/E B (recalibr.)
Capital	94,3%	94,6%	1,003	0,91	0,94
Interior	88,0%	89,6%	1,018	0,98	0,97

Tabela 2. Óbitos neonatais pareados $\times$ não pareados, pelas informações da Declaração de Óbito.

Característica (na DO)	Pareados	Não pareados
n	12.155	1.316
Peso ausente (%)	0,8	26,8
Semanas ausentes (%)	4,8	31,5
Idade da mãe ausente (%)	2,1	32,2
Peso mediano (g)	1.100	1.400
Peso $<$ 1.500 g (%)	60,2	52,1
Óbito no 1º dia (%)	26,5	31,6
Residente na capital (%)	35,0	19,6
Óbito em hospital (%)	98,2	90,2

5.2. Desempenho

A Tabela 3 resume o teste de 2024. No conjunto A, o XGBoost teve AUROC de 0,964 (0,958–0,970) e AUPRC de 0,603 (0,577–0,628), e os 5% de maior risco concentraram 88% dos óbitos. No limiar de 2023, F1 = 0,604, precisão = 0,597 e sensibilidade = 0,610.

Em AUROC, o XGBoost não superou a regressão logística (Δ = 0,001, IC -0,001–0,003, que inclui zero). Em AUPRC, o ganho foi claro: Δ = 0,052 (IC 0,040–0,066). Ou seja, os dois ordenam os nascimentos de forma quase igual, mas o XGBoost é mais preciso entre os de maior risco. O LightGBM empatou com o XGBoost.

No conjunto B, o XGBoost teve AUROC de 0,891 (0,879–0,902) e AUPRC de 0,390 (0,360–0,418). A diferença em relação a A foi ΔAUROC = 0,074 (IC 0,064–0,084) e ΔAUPRC = 0,214 (IC 0,191–0,241), e os 5% de maior risco concentraram 71% dos óbitos.

Tabela 3. Desempenho no teste de 2024 (IC 95% por bootstrap). AUROC, AUPRC e top 5% pelo escore bruto; F1, precisão e sensibilidade no limiar escolhido em 2023.

Conj.	Modelo	AUROC	AUPRC	F1	Precisão	Sensib.	Top 5%
A	LR	0,963 (0,956–0,969)	0,551 (0,526–0,579)	0,554	0,534	0,577	88%
A	XGBoost	**0,964 (0,958–0,970)**	**0,603 (0,577–0,628)**	0,604	0,597	0,610	88%
A	LightGBM	0,964 (0,958–0,970)	0,580 (0,552–0,608)	0,596	0,610	0,583	88%
B	LR	0,886 (0,874–0,896)	0,366 (0,338–0,394)	0,450	0,434	0,467	71%
B	XGBoost	**0,891 (0,879–0,902)**	**0,390 (0,360–0,418)**	0,454	0,470	0,440	71%
B	LightGBM	0,890 (0,879–0,901)	0,396 (0,367–0,424)	0,457	0,466	0,448	71%
Batista et al. (SP)		0,971	0,586	0,548	0,729	0,440	>90%

5.3. Explicabilidade (XAI)

Usamos o SHAP (TreeSHAP exato) [Lundberg and Lee 2017], que decompõe o log-odds previsto de cada nascimento em contribuições aditivas das variáveis, $\operatorname{logit}\hat{p} = \phi_0 + \sum_j \phi_j$, numa amostra de 20.000 nascimentos de 2024. A análise tem cinco partes:

(i) Verificação. $\phi_0 + \sum_j \phi_j$ reproduz o log-odds do modelo avaliado com erro máximo de 7×10^{-6} (A) e 6×10^{-6} (B). A verificação expôs uma armadilha: com *early stopping*, a API do XGBoost usa por padrão todas as árvores treinadas, inclusive as 50 posteriores à melhor iteração. É preciso restringir às árvores do modelo avaliado, senão as explicações se referem a outro modelo.

(ii) Global. As cinco principais variáveis pela importância média $|\phi|$ foram, no modelo A, peso ao nascer, Apgar 5º min, Apgar 1º min, semanas de gestação, anomalia congênita (as mesmas do artigo) e, no B, semanas de gestação, consultas de pré-natal, escolaridade da mãe, apresentação, raça/cor da mãe.

(iii) Dependência. Os efeitos aprendidos são clinicamente plausíveis (Figura 1). O risco cai de forma monotônica com o Apgar, o peso e a idade gestacional, estabilizando a termo, e no modelo B cresce com a idade da mãe acima de ≈37 anos. As consultas de pré-natal têm forma de U: o risco sobe acima de ≈17 consultas, o que é compatível com confusão por indicação (gestações de alto risco são mais acompanhadas). A forma de U mostra que o SHAP descreve associação no modelo, e não efeito causal.

(iv) Local. A Figura 2 explica três casos do teste, partindo do risco médio do modelo (ϕ_0 = 6,18%):

- **Óbito bem previsto:** 670 g, 22 semanas, Apgar 1/1 e com anomalia.
- **Óbito não sinalizado** (risco de 4,4%): recém-nascido a termo (39 semanas, 3.450 g, Apgar 7/8) com anomalia. A anomalia é a única contribuição grande. O indicador binário não distingue malformações letais; o tipo de anomalia (`CODANOMAL`, CID) está na DN, mas não foi usado.
- **"Sobrevivente" com risco de 100,0%:** 385 g, 21 semanas e Apgar 1/1. Esse quadro é incompatível com a sobrevivência, o que indica quase certamente um óbito não pareado. Óbitos sem peso na DO só são pareados em 20,7% dos casos.

Ou seja, os erros vêm de falta de informação na DN ou de erro de rótulo, e não de efeitos espúrios. A explicação local expõe o ruído de rótulo do próprio linkage.

(v) Estabilidade e atributos sensíveis. O ranking de importância é estável: a correlação de Spearman entre XGBoost e LightGBM foi de 0,90 (A) e 0,98 (B), com 4 das 5 principais em comum, e entre metades da amostra, de 0,999. Raça/cor e escolaridade da mãe respondem por 3,0% da importância total no modelo A e 7,9% no B. No modelo B, ter mãe branca reduz o log-odds em média (-0,11) e ter mãe preta aumenta (0,06); a escolaridade vai de 0,33 (fundamental incompleto) a -0,27 (superior). Sem as variáveis do recém-nascido, o modelo B usa o gradiente socioeconômico como substituto de parte do risco; o peso desses atributos, embora pequeno, precisa ser discutido antes de qualquer uso.

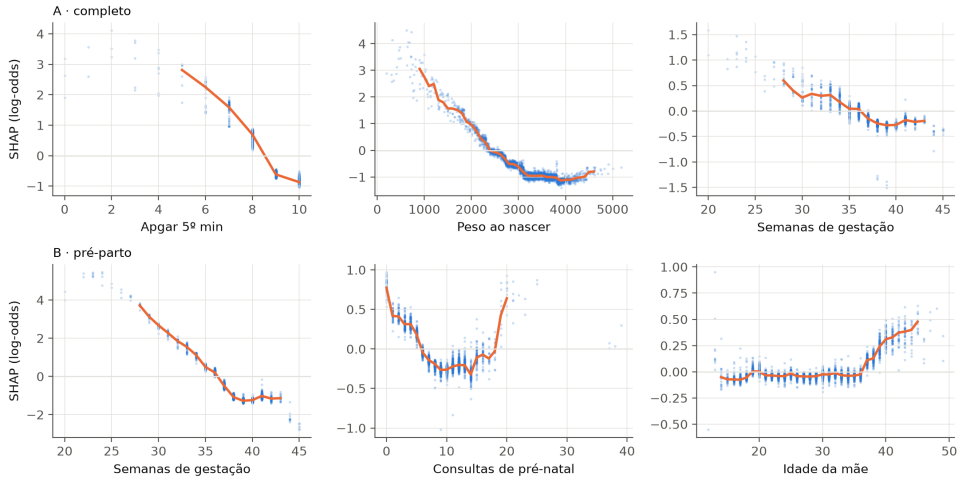


Figura 1. Dependência SHAP: contribuição (log-odds) em função do valor da variável; a linha é a mediana por valor.

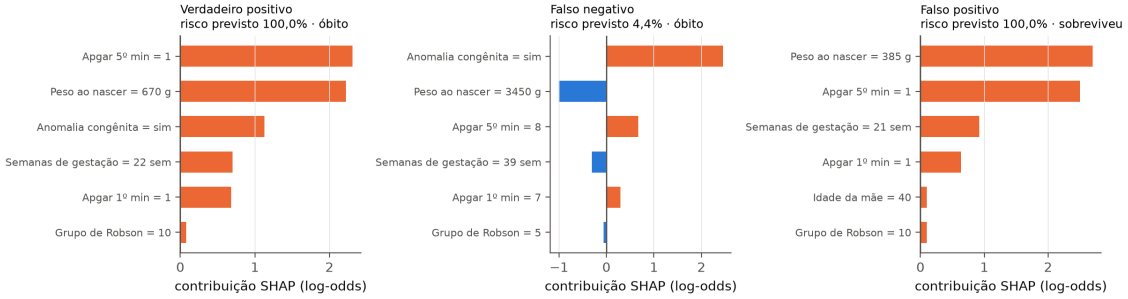


Figura 2. Explicações locais (SHAP) de três casos do teste de 2024, no modelo A: as 6 maiores contribuições.

5.4. Calibração, utilidade clínica e subgrupos

Calibração. A curva de calibração (Figura 3, à esquerda) acompanha a diagonal nas faixas de maior risco, e as inclinações são próximas de 1 (recalibrados: intercepto -0,082 (-0,154 a -0,011) e inclinação 1,009 (0,981 a 1,037) no A; -0,060 (-0,124 a 0,004) e 0,979 (0,954 a 1,005) no B). A recalibração foi *indispensável*. A busca escolheu o peso de classe $\sqrt{n_0/n_1} \approx 11$ para o XGBoost, e com isso o escore bruto superestima muito o risco: O/E

de 0,23 (A) e 0,17 (B), intercepto de -2,456 (-2,526 a -2,387) (curvas pontilhadas). A isotônica corrige isso para 0,95 e 0,96. A leve superestimação que resta (interceptos negativos) é compatível com o *drift*: a isotônica foi ajustada em 2023, quando a TMN foi de 8,20‰, e no teste ela caiu para 7,98‰. É uma explicação plausível, não uma prova, porque a magnitude não coincide exatamente.

Utilidade clínica. Com prevalência de 0,8%, a estratégia de tratar todos tem benefício negativo em qualquer limiar acima de 0,8%, então a comparação relevante é com não intervir. A faixa de limiares foi escolhida pelo uso clínico: para uma transferência *in utero* ou a priorização de UTI neonatal, é plausível aceitar de 9 a 49 falsos alarmes por óbito identificado, o que corresponde a p_t entre 2% e 10%. Nessa faixa (Figura 3, à direita), o benefício líquido do modelo A vai de 6,2 a 4,9 por mil nascidos vivos, e o do B, de 4,7 a 3,3, sempre acima de zero. O máximo possível é a própria TMN, 7,98.

H3. A hipótese previa pior calibração na baixa escolaridade. Mas o O/E de mães com fundamental incompleto foi de 0,99 (0,90–1,09) no modelo B e 0,99 (0,90–1,08) no A, com IC que incluem 1 e se sobrepõem aos do ensino superior (0,94 (0,85–1,05) em B), então H3 não se confirmou. Os subgrupos (figura no material suplementar) mostram dois achados:

- **Discriminação:** no modelo A, ela é pior na baixa escolaridade, com AUROC de 0,950 (0,932–0,965) contra 0,980 (0,970–0,989) no ensino superior e IC que não se sobrepõem.
- **Calibração:** no modelo A, os O/E ficam abaixo de 1 na maioria dos subgrupos, refletindo a leve superestimação global (O/E 0,95). Ela é mais marcada na capital (0,91 (0,85–0,97)) e no ensino superior (0,92 (0,84–1,00)); nenhum subgrupo é subestimado. No teste de 2023, os achados eram outros: o modelo B subestimava mães brancas (O/E 1,15) e o interior (1,08), e no teste de 2024 isso não se repetiu (1,02 (0,94–1,11) e 0,97 (0,91–1,02)). Diferenças de calibração por subgrupo são, portanto, instáveis de um ano para outro.

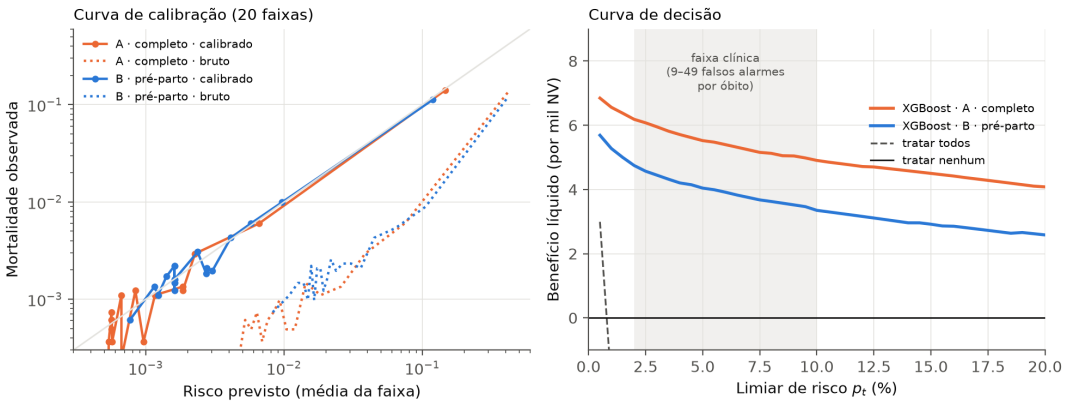


Figura 3. Teste de 2024. Esquerda: curva de calibração em 20 faixas de risco (escala log), com probabilidade recalibrada (linha cheia) e bruta (pontilhada). Direita: curva de decisão, com benefício líquido por mil nascidos vivos e faixa clínica sombreada.

5.5. Sensibilidade ao linkage

O XGBoost foi reajustado com os mesmos hiperparâmetros e rótulos alternativos no ajuste e na validação: **estrito**, sem os nascimentos pareados nas passadas 3–6, e **pior caso**, com esses nascimentos rotulados como sobreviventes. Os dois foram avaliados no *mesmo* teste de 2024 completo, com Δ por bootstrap pareado. A discriminação praticamente não muda: ΔAUROC = -0,0009 (-0,0020 a 0,0001) (estrito) e -0,0013 (-0,0029 a 0,0005) (pior caso) no modelo A, e 0,0006 (-0,0015 a 0,0029) e 0,0013 (-0,0009 a 0,0034) no B. Isso mostra que o modelo é robusto a ruído de rótulo *no treino*. Já o O/E sobe para 1,07–1,16, porque com menos positivos no treino o modelo aprende uma prevalência menor.

O *teste* também tem rótulos imperfeitos. Avaliando o modelo principal sem os pares tolerantes do teste, a AUROC é de 0,965 (A) e 0,890 (B); marcando-os como sobreviventes, é de 0,964 e 0,890. Os pares tolerantes não inflam a AUROC reportada. Já os $\approx$10% de óbitos sem nenhum par não podem ser avaliados, o que é um limite da validação.

6. Aprofundamento (v2): questões para publicação

Todas as análises desta seção reaproveitam os hiperparâmetros do experimento principal e, salvo indicação, avaliam no *mesmo* teste de 2024, com Δ por bootstrap pareado. O código está em `src/aprofundamento.py`.

6.1. Q1: um escore clínico simples basta?

Ajustamos regressões logísticas só com peso, idade gestacional e Apgar 5, e com essas três mais a anomalia congênita, escolhendo C e recalibrando em 2023 como no modelo principal (Tabela 4).

Tabela 4. Q1: escores simples $\times$ XGBoost completo (teste de 2024; Δ por bootstrap pareado).

Modelo (conjunto A)	AUROC	AUPRC	Top 5%	ΔAUROC XGBoost $-$ modelo
XGBoost, 28 variáveis	0,964	0,603	88%	–
Regressão logística, todas	0,963	0,551	88%	0,001 ($-$0,001 a 0,003)
LR, peso + IG + Apgar 5	0,947	0,490	84%	0,017 (0,013 a 0,022)
LR, peso + IG + Apgar 5 + anomalia	0,960	0,522	88%	0,005 (0,002 a 0,007)

Com três variáveis, a AUROC foi de 0,947, a 0,017 (0,013 a 0,022) do XGBoost. Com a anomalia, subiu para 0,960, a só 0,005 (0,002 a 0,007), e os 5% de maior risco concentraram 88% dos óbitos. A diferença que resta está na AUPRC: 0,522 contra 0,603 (Δ = 0,081 (0,064 a 0,097)). **Resposta:** quase toda a ordenação vem de quatro campos da DN; o ganho do XGBoost se concentra na precisão entre os nascimentos de maior risco. A contribuição do trabalho, portanto, não é o algoritmo, e sim os dados abertos, o linkage, a calibração e a avaliação de equidade.

6.2. Q2: há vazamento na DN?

A DN deveria ser preenchida no nascimento. Se campos como a anomalia fossem completados depois do óbito, as DN preenchidas depois seriam previstas melhor. Testamos isso de duas formas.

Por idade no óbito. Cada faixa foi comparada com todos os sobreviventes do teste. A AUROC do modelo A cai de 0,988 no dia 0 para 0,968 entre 1 e 6 dias e 0,934 entre 7 e 27 dias (Figura 4). O mesmo gradiente aparece no modelo B (0,921, 0,898 e 0,848), que não tem Apgar nem anomalia. Ele reflete, portanto, a gravidade: quem morre no dia 0 é, em geral, extremamente prematuro.

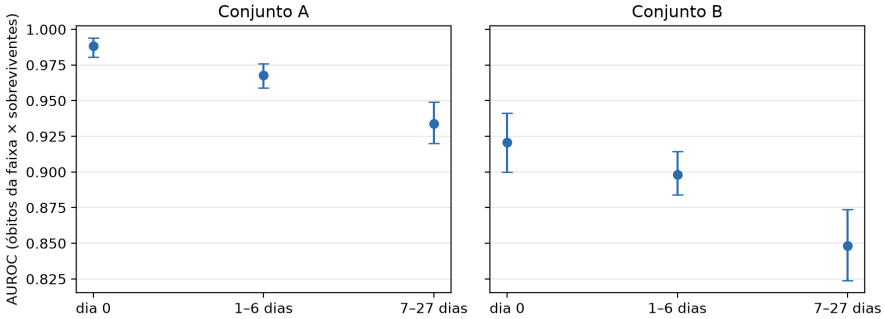


Figura 4. Q2: AUROC por faixa de idade no óbito (óbitos da faixa × todos os sobreviventes), com IC 95%.

Pela data da declaração. A DN traz a data em que foi preenchida (`DTDECLARAC`). No teste, 10% dos óbitos (130) tiveram a DN declarada depois do óbito, e 29% no dia 0. A digitação (`DTCADASTRO`) é posterior ao óbito em 91% dos casos e por isso não discrimina. Comparamos os dois grupos dentro da mesma faixa de idade, o que controla a gravidade (Tabela 5). No dia 0, a AUROC foi de 0,990 com DN declarada depois e 0,988 com DN declarada até o dia do óbito, com IC sobrepostos. Entre 1 e 6 dias, a diferença foi maior (0,986 contra 0,967, com só 23 óbitos no primeiro grupo), mas apareceu igualmente no modelo B (0,949 contra 0,896), que não contém os campos que poderiam ser preenchidos com conhecimento do óbito. **Resposta:** não há evidência de vazamento além da gravidade.

Tabela 5. Q2: AUROC dos óbitos com DN declarada depois do óbito × até o dia do óbito, na mesma faixa de idade (contra todos os sobreviventes).

Conj. / faixa	DN declarada	Óbitos	AUROC (IC 95%)	Top 5%
A, dia 0	depois do óbito	107	0,990 (0,979–0,997)	96%
A, dia 0	até o dia do óbito	263	0,988 (0,980–0,994)	95%
A, 1–6 dias	depois do óbito	23	0,986 (0,976–0,994)	91%
A, 1–6 dias	até o dia do óbito	549	0,967 (0,958–0,975)	88%
B, dia 0	depois do óbito	107	0,931 (0,901–0,963)	80%
B, dia 0	até o dia do óbito	263	0,916 (0,893–0,938)	80%
B, 1–6 dias	depois do óbito	23	0,949 (0,921–0,973)	65%
B, 1–6 dias	até o dia do óbito	549	0,896 (0,881–0,913)	70%

6.3. Q3 e Q4: pandemia e variáveis de chave

Reajustamos o XGBoost sem 2020–2021 no ajuste (Q3) e sem as cinco variáveis que também entram nas chaves do linkage: peso, idade da mãe, semanas, gravidez e parto (Q4). A Tabela 6 mostra os resultados.

Tabela 6. Q3 e Q4: XGBoost reajustado com os mesmos hiperparâmetros (teste de 2024; Δ por bootstrap pareado).

Conj.	Variante	AUROC	AUPRC	ΔAUROC variante − principal
A	principal	0,964	0,603	–
A	sem 2020–2021 no ajuste	0,964	0,606	−0,0001 (−0,0010 a 0,0007)
A	sem variáveis de chave	0,956	0,492	−0,0081 (−0,0107 a −0,0057)
B	principal	0,891	0,390	–
B	sem 2020–2021 no ajuste	0,889	0,389	−0,0014 (−0,0045 a 0,0014)
B	sem variáveis de chave	0,801	0,085	−0,0892 (−0,0997 a −0,0787)

Q3. Sem os anos de pandemia, ΔAUROC = −0,0001 (−0,0010 a 0,0007) (A) e −0,0014 (−0,0045 a 0,0014) (B), com IC que incluem zero. A pandemia não distorceu o treino.

Q4. No modelo A, sem as variáveis de chave, a AUROC cai pouco (Δ = −0,0081 (−0,0107 a −0,0057)), porque o Apgar e a anomalia carregam boa parte da informação, mas a AUPRC cai muito (Δ = −0,1110 (−0,1292 a −0,0955)). No modelo B, a queda é grande: AUROC de 0,801 (Δ = −0,0892 (−0,0997 a −0,0787)), porque sai a idade gestacional. O modelo pré-parto depende, portanto, de um campo que também define quem recebe rótulo. Como a sensibilidade da Seção 5.5 mostrou que os pares tolerantes não alteram a discriminação, essa dependência não parece criar um artefato; mas ela reforça que erros na idade gestacional afetam ao mesmo tempo o linkage e a predição.

6.4. Q5: janelas temporais e *drift*

Para cada ano de teste t entre 2020 e 2024, o modelo foi ajustado até $t-2$, recalibrado em $t-1$ e testado em t (*reajustado*). O modelo *congelado* é o da primeira janela (ajuste em 2017–2018), aplicado aos anos seguintes sem reajuste nem recalibração (Figura 5).

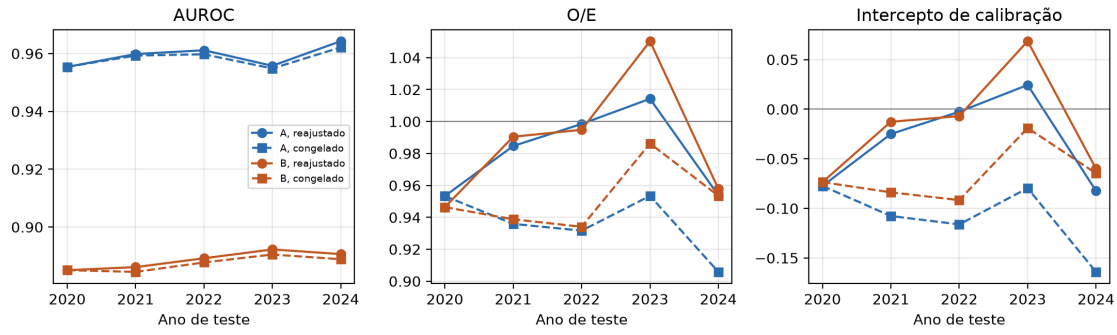


Figura 5. Q5: AUROC, O/E e intercepto de calibração por ano de teste; modelo reajustado todo ano (linha cheia) × congelado desde a primeira janela (tracejada).

A discriminação é estável: a AUROC do modelo A reajustado ficou entre 0,955 e 0,964, e a do congelado, em 0,962 no último ano. A calibração, não. O O/E do modelo reajustado oscilou entre 0,95 e 1,01, acompanhando a TMN de cada ano, e o do congelado caiu até 0,91 em 2024 (intercepto −0,16), superestimando o risco de forma crescente. **Resposta:** o modelo não precisa ser retreinado para ordenar bem, mas precisa

ser recalibrado periodicamente. Uma ressalva: o modelo congelado também foi ajustado com menos anos.

6.5. Q6: simulação de padrão-ouro do linkage

Sem acesso à base identificada, fabricamos uma verdade conhecida. As DN dos 12.155 nascidos efetivamente pareados viraram "DO sintéticas", com a taxa de ausência de cada campo observada nas DO reais e erros por campo em três cenários (baixo, realista e alto: peso ±10–100 g, idade da mãe ±1 ano, semanas ±1–2, estabelecimento trocado por transferência). O linkage rodou contra toda a base, e os demais nascidos serviram de distratores. Em dois cenários adicionais, 5% e 10% das DN verdadeiras foram retiradas da base, simulando sub-registro ou residência diferente na DN e na DO (Tabela 7 e Figura 6).

Tabela 7. Q6: falsos pares reais e estimados pelo modelo de mistura, por passada e cenário, e desempenho da etapa probabilística (FS).

	Falsos pares por cenário: real / estimado (%)				
Passada	baixo	realista	alto	+5% sem DN	+10% sem DN
1	0 / 0	0 / 0	0 / 0	0 / 0	0 / 0
2	0 / 0	0 / 1	0 / 1	0 / 2	0 / 1
3	0 / 4	0 / 2	1 / 8	0 / 2	0 / 0
4	3 / 2	4 / 0	1 / 2	4 / 0	7 / 4
5	0 / 2	1 / 0	2 / 6	5 / 0	9 / 1
6	1 / 5	2 / 4	7 / 10	27 / 26	44 / 28
Falsos no total (real)	0,0%	0,2%	0,4%	0,8%	1,5%
Óbitos com par verdadeiro	98,6%	96,7%	92,6%	91,9%	87,0%
Etapa FS: pares (falsos reais)	2 (100%)	15 (33%)	30 (27%)	19 (58%)	25 (64%)

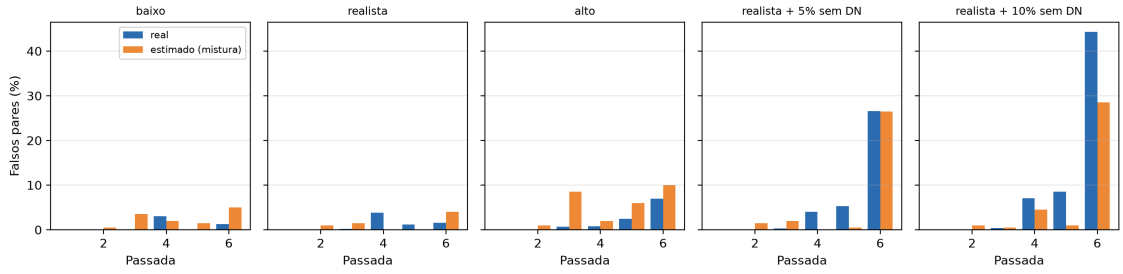


Figura 6. Q6: fração real (azul) e estimada (laranja) de falsos pares por passada, em cada cenário da simulação.

Três resultados:

- **Quando a DN verdadeira existe, a cascata é precisa.** Mesmo no cenário de ruído alto, os falsos pares ficaram em 0,4% no total e no máximo 7% numa passada, e 92,6% dos óbitos receberam o par verdadeiro.
- **A DN ausente concentra os falsos pares na chave mais tolerante.** Com 5% e 10% das DN ausentes, a passada 6 chegou a 27% e 44% de falsos pares, porque o óbito sem DN acaba pareado com um nascido parecido do mesmo hospital.

- **O estimador de mistura é impreciso.** Ele acompanha a ordem de grandeza, mas erra por vários pontos nas passadas pequenas e *subestima* os falsos pares quando há DN ausente (passada 6 com 10% ausentes: 44% reais contra 28% estimados). Nos dados reais, porém, ele estima 17–31% na passada 3, valor que nenhum cenário reproduz. Uma explicação é que a premissa de concordância constante (c_{verd} igual em todas as passadas) falha quando os registros das passadas tolerantes também têm escolaridade e perdas fetais mais mal preenchidas, o que infla a estimativa. As taxas estimadas na primeira parte devem ser lidas como ordem de grandeza, não como medida.

6.6. Q7: etapa probabilística (Fellegi–Sunter)

Sobre os 1.316 óbitos que a cascata não pareou, comparamos cada óbito com os nascidos ainda livres da mesma data e sexo (347.020 pares candidatos). Cada campo recebe um nível de concordância: exato; próximo (peso $\pm$50 g, idade da mãe e semanas $\pm$1); discorda; ou ausente, que não pesa. O peso do par é

$$w = \sum_j \log_2 \frac{m_j(\gamma_j)}{u_j(\gamma_j)}, \qquad P(\text{par} \mid \gamma) = \frac{1}{1 + 2^{-(w + \log_2[\lambda/(1-\lambda)])}}, \tag{3}$$

com u_j estimado em pares aleatórios do mesmo bloco e m_j nos pares determinísticos em cujas chaves o campo não entra. A proporção λ = 0,0036 supõe no máximo um par verdadeiro por óbito no bloco. Pares com probabilidade $\geq$ 0,9 foram aceitos 1:1, do mais provável para o menos provável [Fellegi and Sunter 1969]. O EM, alternativa usual para m e λ, convergiu para λ = 0,039, dez vezes o plausível: separou "mesmo município" de "outro município", e não pares de não pares.

A etapa aceitou só 13 pares, com falsos pares estimados de 54% e 79%, e nenhum no teste. Os óbitos restantes não são recuperáveis: 71% deles não têm nenhum candidato com probabilidade acima de 0,1, e 726 têm os sete campos preenchidos na DO e ainda assim não encontram par. Isso aponta para DN ausente da base, e não para campos faltantes. Na simulação, o mesmo padrão aparece: a etapa FS gera poucos pares, e com 5–10% de DN ausentes a maioria é falsa (58% e 64%). **Resposta:** com os campos da DO pública, uma etapa probabilística não recupera o resíduo, e o limite do linkage não é o método, e sim a existência da DN na base do mesmo estado.

7. Discussão

H1 foi confirmada. Com dados abertos, o XGBoost teve AUROC de 0,964 e concentrou 88% dos óbitos nos 5% de maior risco, contra 0,971 e mais de 90% no artigo, com as mesmas cinco variáveis principais. O modelo é robusto a ruído de rótulo no treino, e os pares duvidosos do teste não inflam a AUROC. Não é possível descartar, porém, um viés vindo dos óbitos que ficaram sem par.

A diferença residual para o artigo é compatível com três fatores: os $\approx$15% de óbitos sem par verdadeiro, de perfil diferente (mais ausências, mais do interior, mais óbitos precoces fora do hospital); a heterogeneidade do estado; e a pior qualidade da DN e da DO no interior.

H2 foi confirmada em parte. Houve queda real (ΔAUROC = 0,074, ΔAUPRC = 0,214), mas o modelo B manteve AUROC de 0,891 e benefício líquido positivo, quase

tudo pela idade gestacional. O uso adequado é delimitado: estimar, na admissão para o parto, o risco dado que o nascimento ocorre agora. Isso apoia a decisão sobre transferência *in utero* para uma maternidade com UTI neonatal e o preparo da equipe. O modelo não serve para triagem precoce da gestação, porque a idade gestacional do parto e as consultas acumuladas não são conhecidas semanas antes.

H3 não foi confirmada. A calibração na baixa escolaridade não foi pior. O achado de equidade que se sustenta é outro: no modelo A, a *discriminação* é menor para filhos de mães com fundamental incompleto. Uma hipótese é que a DN desses nascimentos tenha pior qualidade de preenchimento. Já as diferenças de calibração por subgrupo mudaram entre os testes de 2023 e 2024, o que desaconselha interpretá-las como viés estrutural.

Para capital e interior, testamos o linkage diferencial. O pareamento é menor no interior (88,2% contra 94,3%), mas quase não mudou entre os anos, e por si só deslocaria o O/E em menos de 2% (Tabela 1). Ele não explica a diferença observada (0,91 contra 0,98 no modelo A).

Para raça/cor, o pareamento é quase uniforme, mas a evidência é indireta, porque usa a raça do recém-nascido, e não a da mãe. [Ramos et al. 2025] encontraram captura equivalente entre grupos, o que é coerente com a nossa discriminação próxima entre grupos de raça/cor (AUROC de 0,976 (0,966–0,983) para mães brancas e 0,962 (0,946–0,976) para pretas, no modelo A).

Calibração e *drift*. Com o peso de classe escolhido pela busca, a calibração depende inteiramente da etapa isotônica. Depois dela, a curva e a inclinação ≈ 1 indicam boa calibração. A calibração absoluta, porém, depende de fatores externos ao modelo: a completude do linkage, vista na sensibilidade, e a variação anual da TMN (8,20‰ em 2023 e 7,98‰ em 2024). Em uso real, seria preciso recalibrar o intercepto periodicamente.

O que a v2 muda na leitura. As perguntas da Seção 6 deslocam a contribuição do trabalho. (i) O algoritmo importa pouco para a ordenação: quatro campos da DN chegam a 0,960 de AUROC, e o ganho do XGBoost está na AUPRC. (ii) O desempenho não é artefato de vazamento, da pandemia nem dos pares tolerantes. (iii) O modelo ordena de forma estável ao longo dos anos, mas a calibração deriva, o que torna a recalibração anual parte do modelo, e não um detalhe. (iv) O linkage sem identificadores é preciso quando a DN existe na base, e o resíduo de $\approx$10% não se recupera com métodos probabilísticos. A causa provável é a DN ausente do arquivo do mesmo estado, por sub-registro ou por residência declarada de forma diferente na DN e na DO. Isso muda o próximo passo: em vez de sofisticar o pareamento, é preciso ampliar a base de busca, por exemplo pareando o resíduo com as DN das UF vizinhas.

Limitações. Os rótulos são imperfeitos ($\approx$15% dos óbitos sem par verdadeiro); a validação é temporal, mas não externa; o modelo A usa variáveis posteriores ao nascimento; o bootstrap ignora a dependência entre gêmeos; a calibração por subgrupo varia de um ano para outro; o SIM 2025 ainda é preliminar; não houve óbitos suficientes para analisar mães amarelas e indígenas; e a simulação de padrão-ouro depende de premissas sobre o tipo e a taxa de erro dos campos, que só uma base identificada pode confirmar.

8. Conclusão

É possível reproduzir, só com dados abertos, um modelo brasileiro de predição de mortalidade neonatal com discriminação próxima à publicada, e essa discriminação é robusta a ruído de rótulo no treino. As explicações SHAP são aditivas, estáveis e clinicamente plausíveis. A calibração absoluta, ao contrário, é sensível ao linkage e ao *drift* temporal. Um modelo na admissão para o parto mantém AUROC de 0,891 e benefício líquido positivo, para decisões de transferência *in utero*.

Na versão 2, o trabalho resistiu às perguntas de um revisor: não há sinal de vazamento, a pandemia não distorce o treino, a discriminação é estável no tempo e a cascata determinística é precisa quando a DN existe. Por outro lado, a v2 mostrou que um escore com quatro campos da DN chega perto do XGBoost, que a calibração exige atualização anual e que o resíduo do linkage não se recupera com uma etapa probabilística.

Como trabalhos futuros, ficam:

- parear o resíduo de óbitos com as DN das UF vizinhas, para testar a hipótese de DN fora da base;
- validar o linkage e o estimador de falsos pares contra uma base identificada (SES-RJ ou CIDACS/Fiocruz);
- fazer a validação externa em outras UFs, com treino numa região e teste em outra;
- usar o tipo de anomalia congênita (`CODANOMAL`);
- avaliar o impacto junto à rede de atenção materno-infantil.

Reprodutibilidade. O código, os testes, o notebook, os geradores deste relatório e dos slides e o manifesto dos dados estão em `https://github.com/CledsonSilvaAraujo/mortalidade-neonatal-rj`. O comando `python -m src.experimento` refaz todos os números da primeira parte a partir do FTP do DATASUS, e `python -m src.aprofundamento`, os da Seção 6. A versão 1 está marcada no repositório com a tag `v1.0`.

Referências

[Akiba et al. 2019] Akiba, T., Sano, S., Yanase, T., Ohta, T., and Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631.

[Batista et al. 2021] Batista, A. F. M., Diniz, C. S. G., Bonilha, E. A., Kawachi, I., and Chiavegatto Filho, A. D. P. (2021). Neonatal mortality prediction with routinely collected data: a machine learning approach. *BMC Pediatrics*, 21:322.

[Chen and Guestrin 2016] Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

[Collins et al. 2024] Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

[Conselho Nacional de Saúde 2016] Conselho Nacional de Saúde (2016). Resolução nº 510, de 7 de abril de 2016. Diário Oficial da União, 24 maio 2016.

[Fellegi and Sunter 1969] Fellegi, I. P. and Sunter, A. B. (1969). A theory for record linkage. *Journal of the American Statistical Association*, 64(328):1183–1210.

[Ke et al. 2017] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, pages 3146–3154.

[Lundberg and Lee 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774.

[Maia et al. 2017] Maia, L. T. S., Souza, W. V., Mendes, A. C. G., and Silva, A. G. S. (2017). Use of linkage to improve the completeness of the SIM and SINASC in the Brazilian capitals. *Revista de Saúde Pública*, 51:112.

[Mangold et al. 2021] Mangold, C., Zoretic, S., Thallapureddy, K., Moreira, A., Chorath, K., and Moreira, A. (2021). Machine learning models for predicting neonatal mortality: A systematic review. *Neonatology*, 118:394–405.

[Ministério da Saúde – DATASUS 2026] Ministério da Saúde – DATASUS (2026). Transferência de arquivos: SINASC e SIM (microdados por uf). `ftp://ftp.datasus.gov.br/dissemin/publicos/`. Acesso em 24 set. 2026.

[Ramos et al. 2025] Ramos, A. P., Caldieraro, F., Nascimento, M. L., and Saldanha, R. (2025). Reducing inequalities using an unbiased machine learning approach to identify births with the highest risk of preventable neonatal deaths. *Population Health Metrics*, 23:59.

[Silva et al. 2025] Silva, G. F. S., Wichmann, R. M., da Silva Junior, F. C., and Chiavegatto Filho, A. D. P. (2025). Development and evaluation of machine learning training strategies for neonatal mortality prediction using multicountry data. *Scientific Reports*, 15:24278.

[Van Calster et al. 2019] Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., and Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17:230.

[Vickers and Elkin 2006] Vickers, A. J. and Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6):565–574.